Statistik1

Rahmen

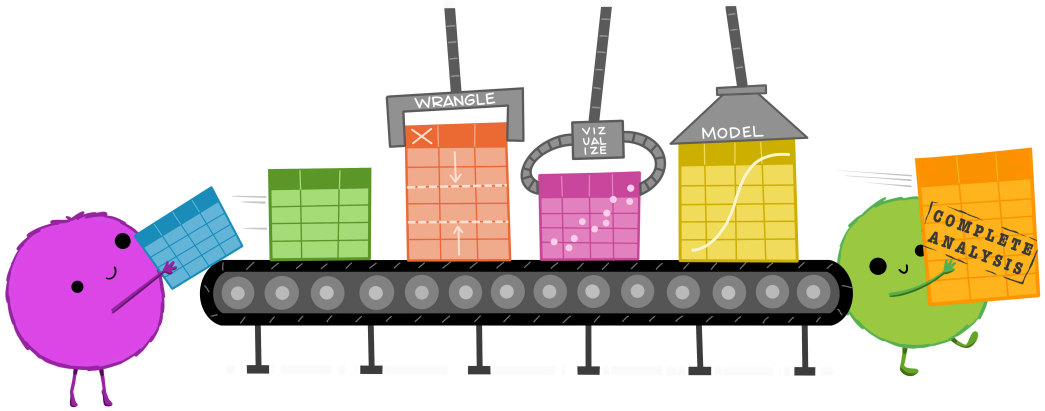
Sebastian Sauer

Einstieg

Lernziele

- Sie können eine Definition von Statistik wiedergeben.
- Sie können eine Definition von Daten wiedergeben.
- Sie können den Begriff Tidy-Daten erläutern.
- Sie können Beispiele für verschiedene Skalenniveaus nennen.

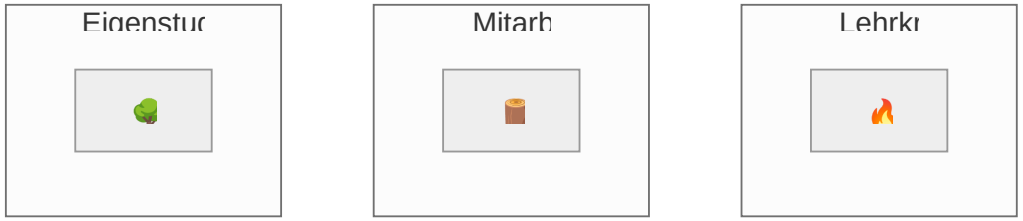
Datenanalyse als Fließband



Datenanalyse als eine Abfolge am Fließband (Horst, 2024)

Schritt für Schritt, in der richtigen Reihenfolge, vom Anfang bis Ende, erarbeiten wir unser “Datenprodukt”.

Ihr Erfolgsrezept



Eine gute Lehrkraft ist der Funke. Ihre Mitarbeit im Unterricht ist das Brennmaterial. Ihr Eigenstudium hält das Feuer am Leben.

Was ist Statistik und wozu ist sie gut?

Definition: Statistik

Definition: Statistik

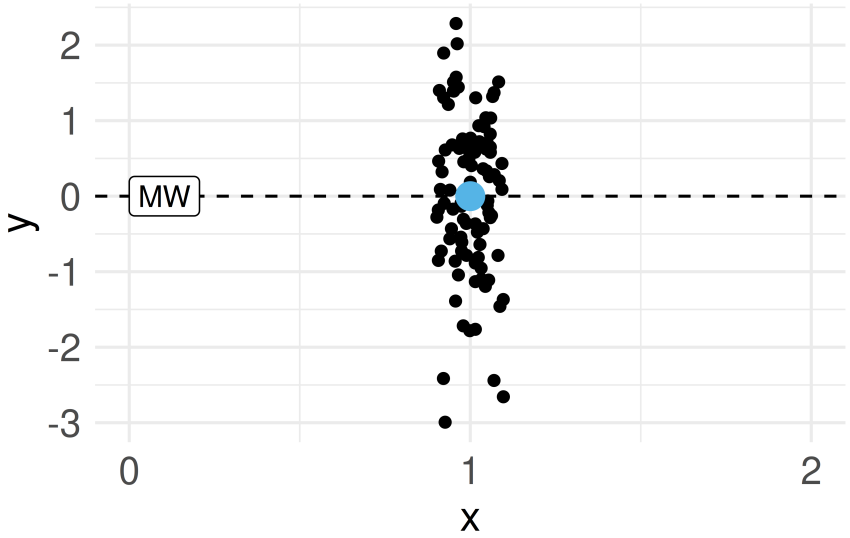
Statistik fasst Werte zusammen, quantifiziert deren Unterschiedlichkeit und beschreibt die Ungewissheit unserer Schlüsse (Kaplan, 2009; Poldrack, 2023).

In diesem Buch werden *Statistik*, *Datenanalyse* und *Data Science* synonym verwendet.

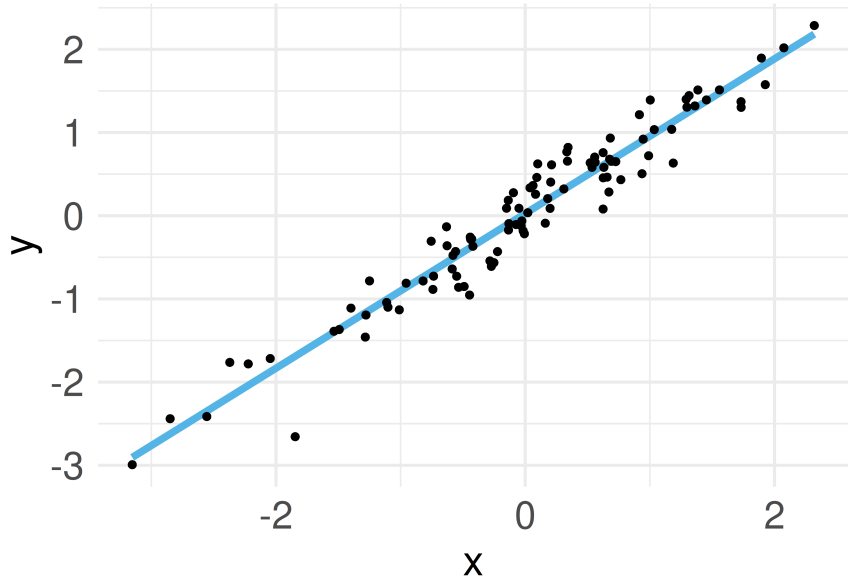
Drei Bestimmungsstücke:

1. Daten zusammenfassen
2. Unterschiedlichkeit quantifizieren
3. Ungewissheit beschreiben

Daten zusammenfassen

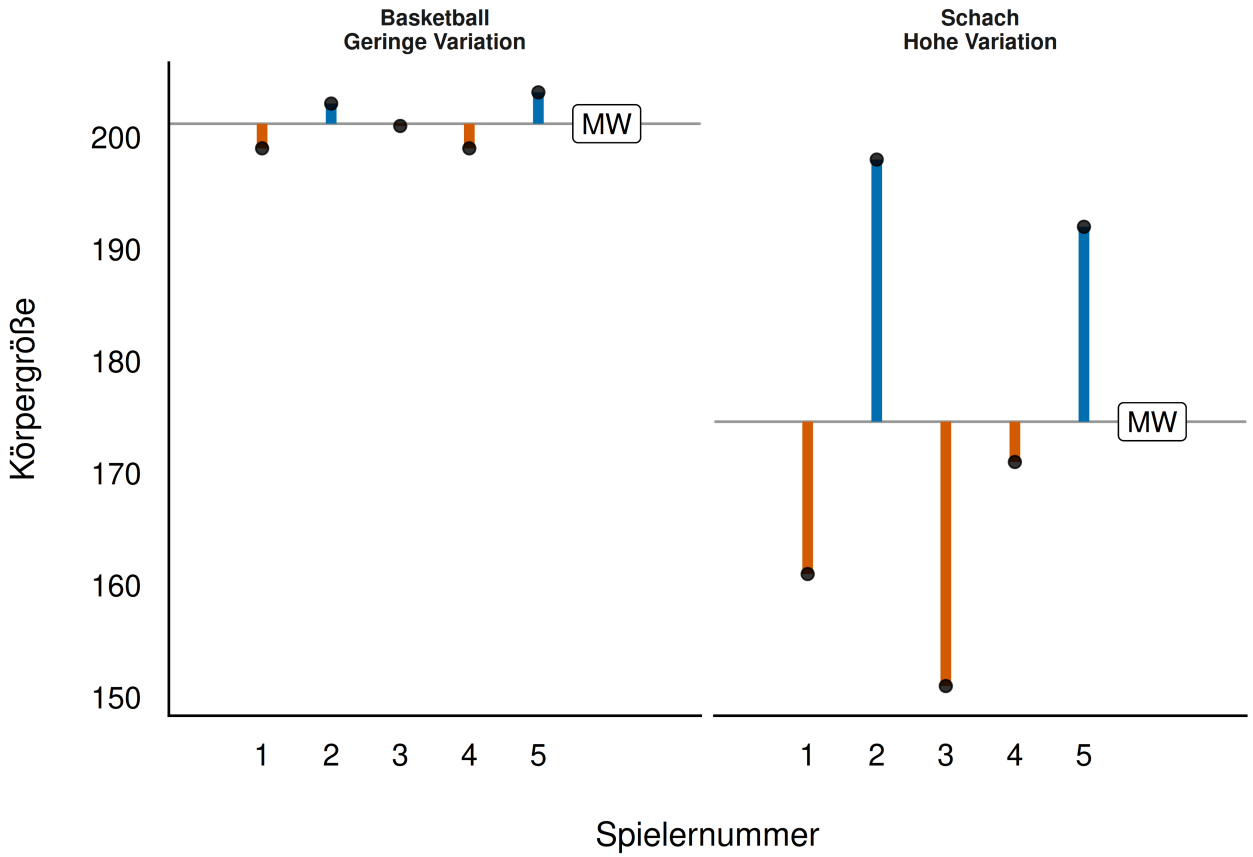


MW: Mittelwert



Eine Menge von Zahlen wird zu einer einzelnen Zahl “zusammengedampft” — leichter zu verstehen als viele Einzelwerte.

Unterschiedlichkeit quantifizieren



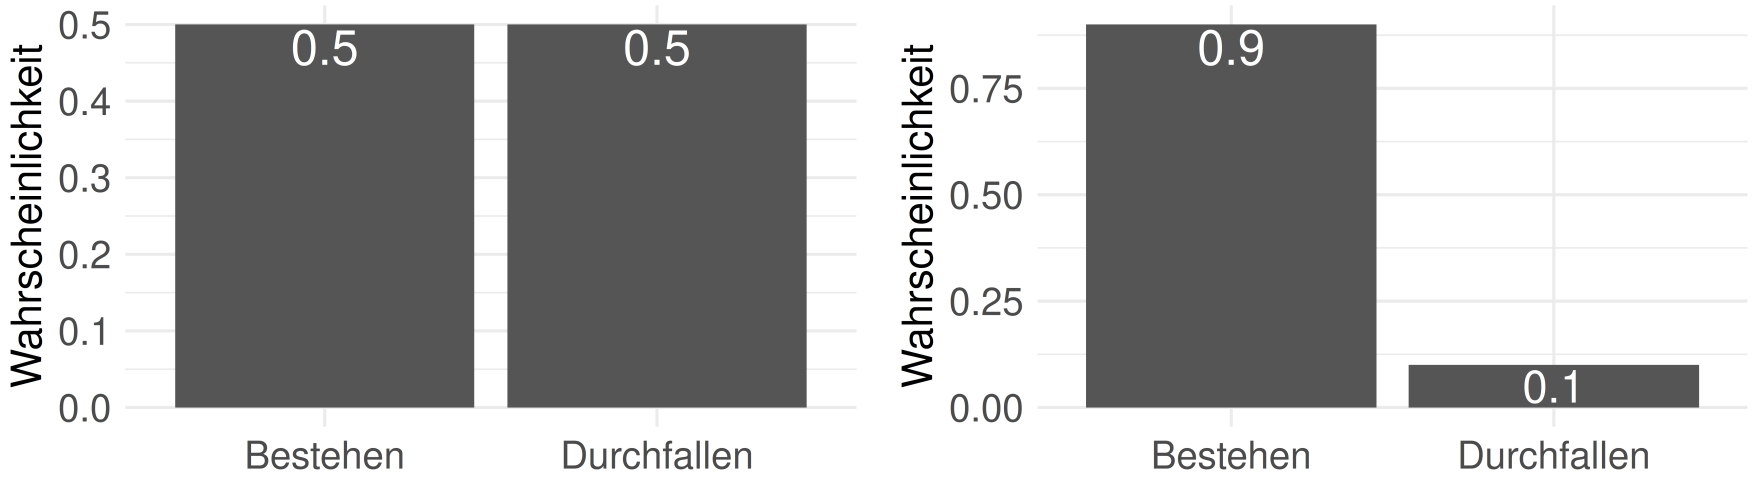
Zentrale Idee: die *Variation der Dinge* präzise beschreiben.

Definition: Residuum

Definition: Residuum

Das Residuum des Merkmals X der i-ten Beobachtung ist die Differenz vom Wert x_i und einem Referenzwert, etwa dem Mittelwert ($\bar{x}$): $r_i = x_i - \bar{x}$.

Ungewissheit beschreiben: Anna & Berta



Anna hat keine Ahnung, ob sie die Klausur bestanden hat. Berta ist sich sehr sicher. Beide unterscheiden sich in ihrer Ungewissheit.

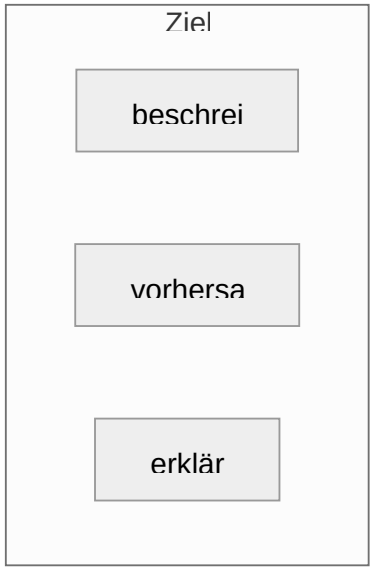
Ungewissheit beschreiben: Der zwielichtige Statistiker

Ein Statistiker wirft eine Münze 10 Mal; bei Kopf gewinnt er. Er gewinnt 8 von 10 Mal.

- *Sie* sind sich *ziemlich* sicher, dass er Sie über den Tisch gezogen hat — aber nicht ganz sicher.
- *Der Statistiker* ist sich *ganz sicher*: Er weiß, dass seine Münze gezinkt ist.

Was ist das Ziel Ihrer Analyse?

Arten von Zielen



Was ist das Ziel Ihrer Analyse?

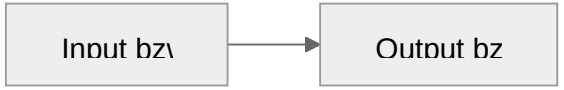
Beispiele für Zielarten

- *Beschreiben*: Wie groß ist der Gender-Paygap in der Branche X im Zeitraum Y?
- *Vorhersagen*: Wenn ich 100 Stunden lerne, welche Note kann ich erwarten?
- *Erklären*: Wie viel bringt mir das Lernen für die Klausur?

Forschungsfrage

Die Leitfrage Ihrer Analyse: Was wollen Sie herausfinden?

Häufig: “Hat X einen (kausalen) Einfluss auf Y?”



Beispiele für Forschungsfragen

> Hat Lernen (X) einen Einfluss auf den Prüfungserfolg (Y)?

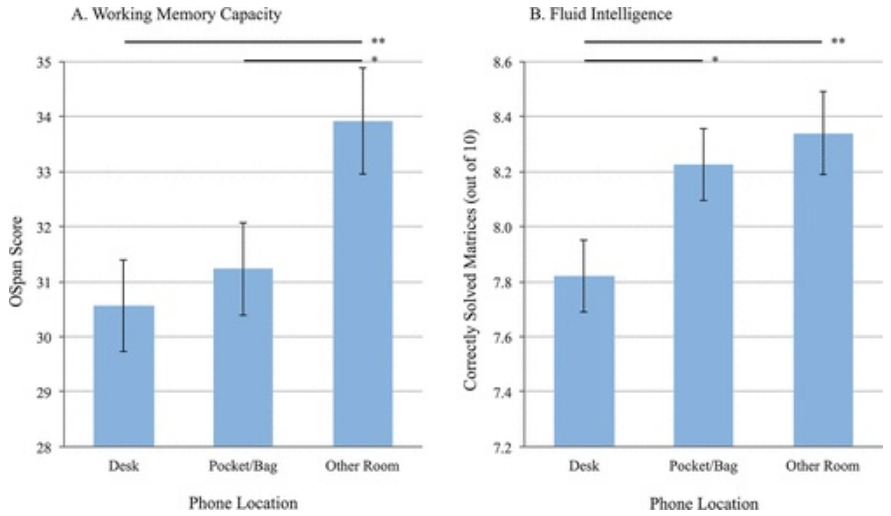
> Verringert Joggen (X) die Menge des Hüftgolds (Y)?

> Um welchen Betrag erhöht sich der Umsatz (Y), wenn wir 1000 Euro mehr für Werbung ausgeben (X)?

> Verringert intensive Handynutzung (X) die Konzentrationsfähigkeit (Y)?

Was ist das Ziel Ihrer Analyse?

Aus der Forschung: Smartphone-Brain-Drain

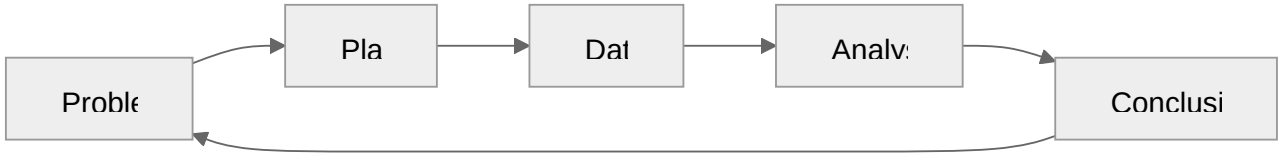


Handy in Sichtweite verringert die kognitiven Ressourcen, Ward et al. (2017), S. 145

Ward et al. (2017): Die bloße Gegenwart eines Handys reduziert die verfügbare kognitive Kapazität — selbst wenn es nur auf dem Tisch liegt.

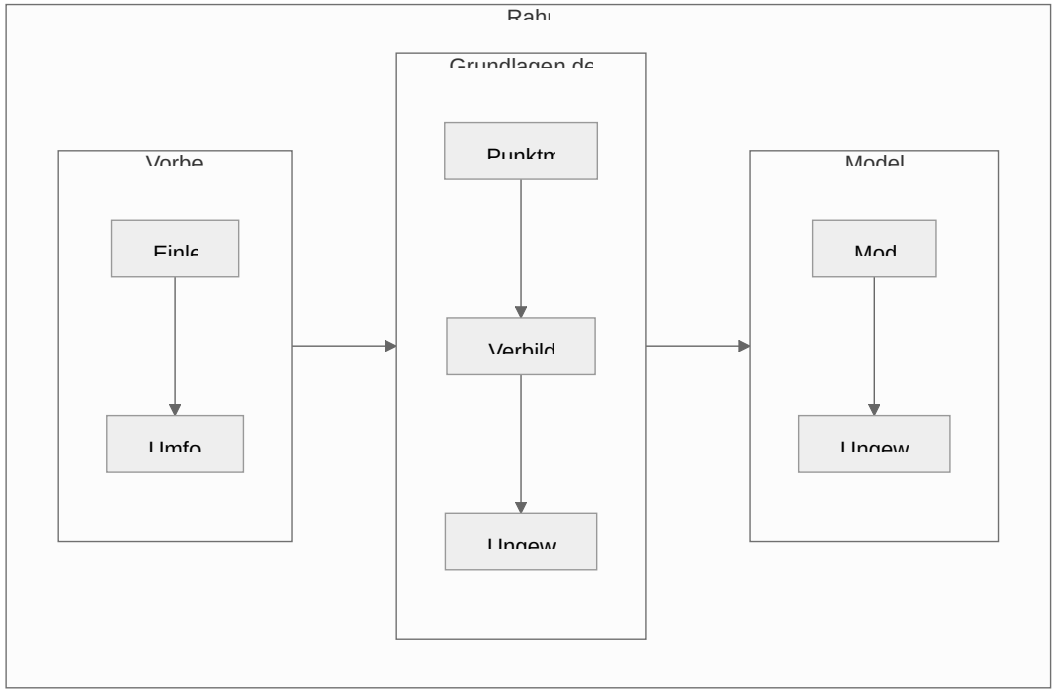
Was ist das Ziel Ihrer Analyse?

Der Prozess der Datenanalyse: PPDAC



- **P**roblem: Problem, Ziel und Sachgegenstand verstehen
- **P**lan: Vorgehen planen
- **D**ata: Daten erheben und aufbereiten
- **A**nalysis: Daten analysieren
- **C**onclusions: Schlussfolgerungen ziehen (MacKay & Oldford, 2000)

Die sieben Schritte der Datenanalyse



Was ist das Ziel Ihrer Analyse?

Was sind Daten?

Definition: Daten

Definition: Daten

Daten sind eine geordnete Folge von Zeichen.

Daten als Tabelle

id	name	note
1	Anna	1.3
2	Berta	2.3
3	Carla	3

Die erste Spalte `id` ist nur eine laufende Nummer zur Identifikation der Beobachtungen — sie birgt sonst keine Information (vgl. Matrikelnummer, Personalausweisnummer, Bestellnummer).

Beispiel: Der Datensatz `mariokart`

Forschungsfrage: Welche Produktmerkmale stehen mit einem hohen Verkaufserlös in Zusammenhang?

Ausschnitt der Variablen: `n_bids`, `start_pr`, `total_pr`, `wheels` — Auktionsdaten zur Spielekonsole Wii / dem Spiel Mariokart.

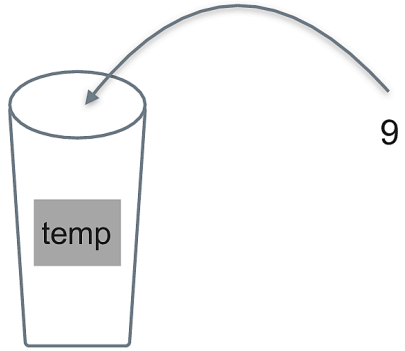
Variable & Beobachtungseinheit

Definition: Variable

Eine Variable ist ein Platzhalter für ein Merkmal, das verschiedene Ausprägungen annehmen kann.

Definition: Beobachtungseinheit

Beobachtungseinheiten sind die Dinge, die wir untersuchen (beobachten). Sie sind die Träger von Variablen.



Wert & Ausprägung

Definition: Wert

Ein *Wert* ist der Inhalt einer Variablen.

Definition: Ausprägung

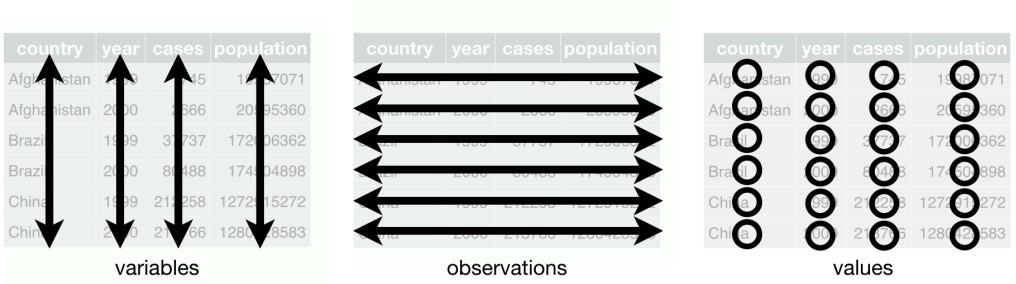
Als *Ausprägungen* bezeichnet man die *verschiedenen* Werte einer Variablen.

Beispiel: Die Variable `geschlecht` bei zehn Probanden enthält die Ausprägungen: divers, Frau, Mann.

Tidy Data

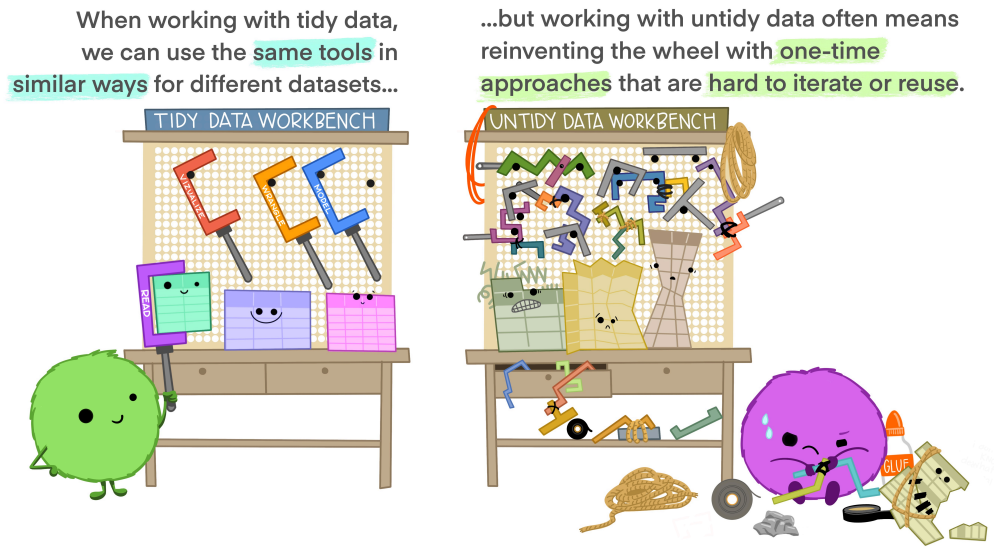
Definition: Tidy Data

Eine Tabelle, in der jede Zeile eine Beobachtungseinheit darstellt, jede Spalte eine Variable und jede Zelle einen Wert.



Tidy-Data-Sinnbild (Wickham, 2023)

Warum Tidy Data?



Immer schön Ordnung halten … (Horst, 2023)

Man weiß, wie die Daten aufgebaut sind — und Statistikprogramme kommen mit diesem Format am besten zurecht.

Beispiel: Breit- vs. Langformat

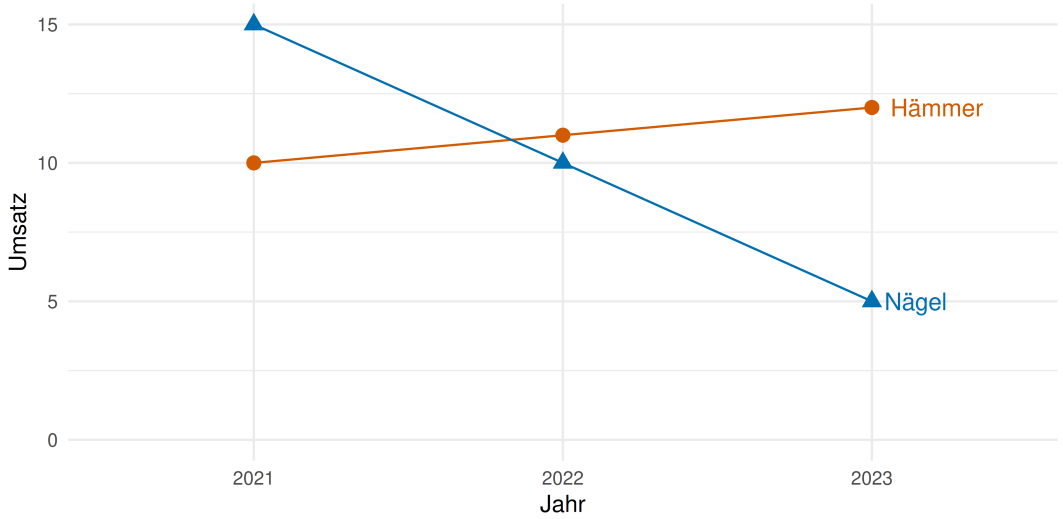
Breitformat (nicht tidy)

Produkt	2021	2022	2023
Hämmer	10	11	12
Nägel	15	10	5

Langformat (tidy)

Produkt	Jahr	Umsatz
Hämmer	2021	10
Hämmer	2022	11
…	…	…

Visualisierung dank Tidy Data



Ohne Tidy-Daten wäre dieses Diagramm nicht so einfach zu erstellen.

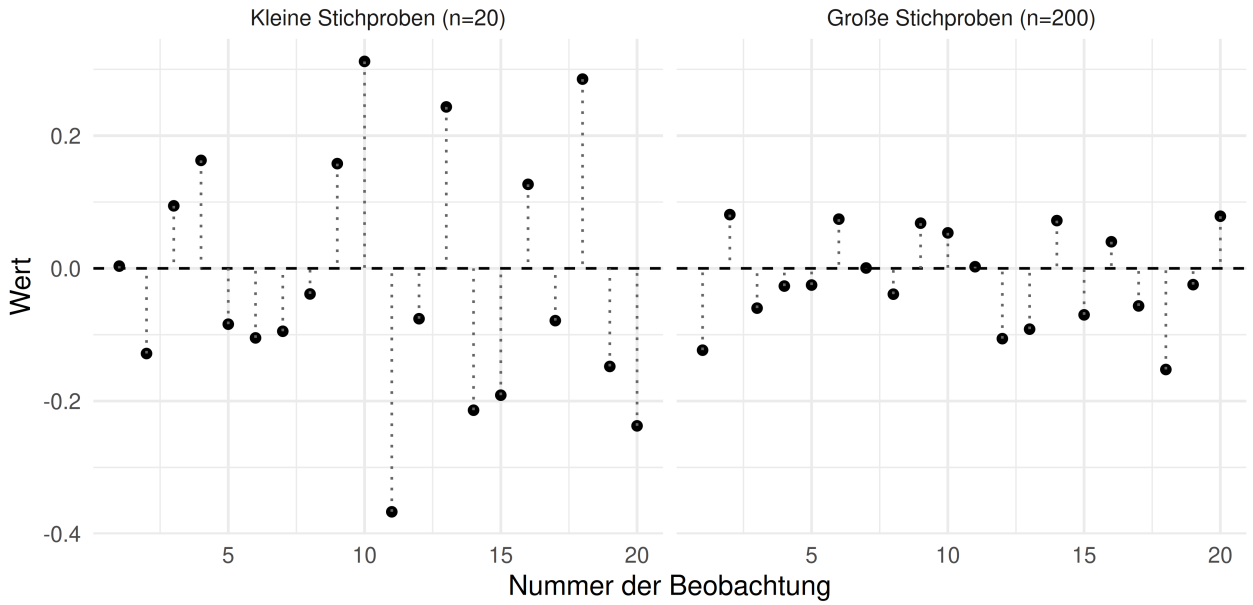
Je mehr, desto besser (?)

“Viel hilft viel” — aber nur unter sonst gleichen Umständen.
Viel Datenmüll ist nicht besser als ein paar knappe, wasserdichte Fakten!

Wichtig

Mehr Daten = genauere Ergebnisse (unter sonst gleichen Umständen)

Stichprobengröße und Genauigkeit

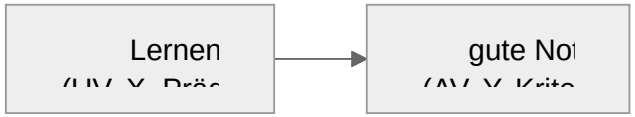


Kleine Stichproben ($n = 20$) streuen stärker um den wahren Mittelwert als große Stichproben ($n = 200$).

Arten von Variablen

Nach Position in der Forschungsfrage

> Hat Lernen einen Einfluss auf den Prüfungserfolg?

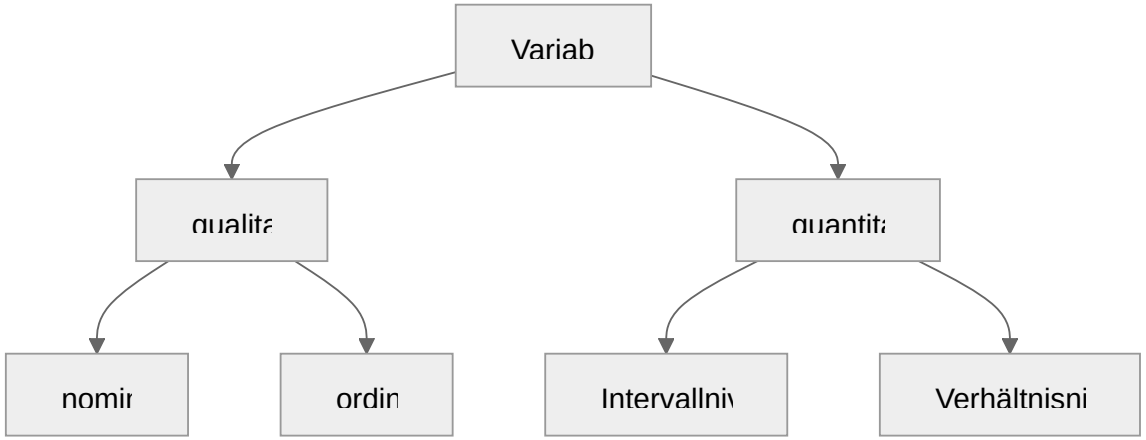


Lernen ist die Input-Variable (X, Ursache, UV). *Prüfungserfolg* ist die Output-Variable (Y, Wirkung, AV).

Definition: Skalenniveau

Definition: Skalenniveau

Der Begriff bezeichnet Art und Menge der Information in Variablen — basierend auf den Eigenschaften der Daten und den mathematischen Operationen, die sinnvoll darauf angewendet werden können.



Beispiele für Skalenniveaus

Variable	Skalenniveau
Haarfarbe, Augenfarbe, Geschlecht, Automarke, Partei	Nominalskala
Lieblingsessen, Medaillen, Uniranking	Ordinalskala
IQ, Extraversion, Temperatur (°C/°F)	Intervallskala
Temperatur (Kelvin), Körpergröße, Geschwindigkeit, Länge	Verhältnisskala

Erlaubte Rechenoperationen

Skalenniveau	**Quantitativ**	$=$	$\preceq$	$+$	$\times$
Nominalniveau	nein	✅	❌	❌	❌
Ordinalniveau	nein	✅	✅	❌	❌
Intervallniveau	ja	✅	✅	✅	❌
Verhältnisniveau	ja	✅	✅	✅	✅

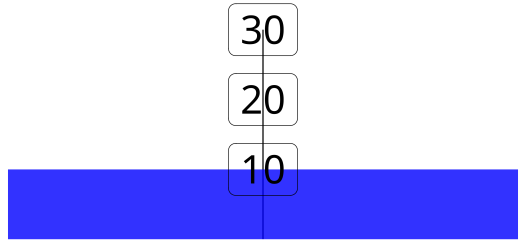
Nominal- & Ordinalskala

Nominalskala (z. B. Geschlecht): Nur *Gleichheit* prüfbar. 👩 ≠ 👨, 👩 = 👩. Codierung (1 = Frau, 2 = Mann) darf nicht verrechnet werden!

Ordinalskala (z. B. Leibgerichte): Objekte lassen sich *ordnen* (🍕 > 🍝 > 🥩), aber die Abstände zwischen den Rängen sind nicht quantifizierbar.

Intervall- & Verhältnisskala

Intervallskala (z. B. Celsius): Der Nullpunkt ist willkürlich (nicht physikalisch). Addieren/Subtrahieren ist erlaubt, aber *nicht* “doppelt so warm”.



Verhältnisskala (z. B. Länge, Kelvin): Alle Rechenoperationen erlaubt, inklusive Verhältnisbildung.

Modelle

Definition: Modelle

Definition: Modelle

Modelle sind ein vereinfachtes Abbild der Realität, eine *Repräsentation* (Kaplan, 2009).



Matchbox-Autos sind Modelle für Autos, (Spurzem, 2017)

Beispiele für Modelle

Puppen sind Modelle für Babys, Landkarten für Landstriche, das Bohrsche Atommodell für Atome.

Prof. Weiss-Ois hat 29 Lernzeiten vor sich und blickt nicht durch — bis man ihm ein Modell gibt: den *Mittelwert*, 9,6 Stunden. Jetzt weiß er, wie viel seine Studierenden typischerweise lernen.

Wozu Modelle?

Modelle vereinfachen komplexe Sachverhalte und machen sie dem Verständnis zugänglich. In der Statistik fassen Modelle oft viele Daten prägnant zusammen, z. B. zu einer einzelnen Kennzahl.

Das Verrückte: Man wirft Informationen weg, um eine (hoffentlich nützlichere) Information zu bekommen (Stigler, 2016). Weniger ist mehr?!

Praxisbezug

Daten im Berufsleben

Wir leben im Datenzeitalter — Daten durchdringen alle Bereiche des beruflichen, gesellschaftlichen und privaten Lebens.

Egal ob man Daten als Segen oder Fluch betrachtet: Mit Daten umgehen zu können, wird immer wichtiger. Datenanalyse gehört zu den stark nachgefragten Jobs.

Wie man mit Statistik lügt

Das File-Drawer-Problem

Von 20 untersuchten Variablen zeigt nur 1 einen interessanten Effekt. Die Versuchung: die anderen 19 in der Schublade verschwinden lassen und nur den einen schönen Befund präsentieren.

Wer missliebige Ergebnisse verschweigt, erzeugt ein verzerrtes Bild der Ergebnislage — man spricht von *Publikationsbias* (Marks-Anglin, Arielle and Chen, Yong, 2020; Rothstein, 2014). Ein Fall von wissenschaftlichem Fehlverhalten.

Zusammenfassung

- **Statistik**: Daten zusammenfassen, Unterschiedlichkeit quantifizieren, Ungewissheit beschreiben
- Drei Ziele der Analyse: beschreiben, vorhersagen, erklären
- **Daten**: geordnete Folge von Zeichen — im *Tidy*-Format am besten nutzbar
- **Variablen**: Position (UV/AV) und Skalenniveau (nominal, ordinal, Intervall, Verhältnis)
- **Modelle**: vereinfachte Repräsentationen der Realität

Literaturhinweise

- Stigler (2016) — Fundamente statistischer Analyse
- Çetinkaya-Runde & Hardin (2021) — Kapitel 1, “Hello data”
- Downey (2023) — statistische Überraschungsmomente, unterhaltsam

Referenzen

Çetinkaya-Runde, M., & Hardin, J. (2021). *Introduction to Modern Statistics*. https://openintro-ims.netlify.app/

Downey, A. (2023). *Probably Overthinking It: How to Use Data to Answer Questions, Avoid Statistical Traps, and Make Better Decisions*. The University of Chicago Press.

Horst, A. (2023). *Tidy Data* [Artwork]. https://allisonhorst.com/

Horst, A. (2024). *Statistics Artwork* [Artwork]. https://allisonhorst.com/

Kaplan, D. T. (2009). *Statistical Modeling: A Fresh Approach*. CreateSpace. https://dtkaplan.github.io/SM2-bookdown/

MacKay, R. J., & Oldford, R. W. (2000). Scientific Method, Statistical Method and the Speed of Light. *Statistical Science*, *15*(3), 254–278. https://doi.org/10.1214/ss/1009212817

Marks-Anglin, Arielle and Chen, Yong. (2020). A Historical Review of Publication Bias. *Research Synthesis Methods*, *11*(6), 725–742. https://doi.org/10.1002/jrsm.1452

Poldrack, R. A. (2023). *Statistical Thinking: Analyzing Data in an Uncertain World*. Princeton University Press. https://statsthinking21.github.io/statsthinking21-core-site/

Rothstein, H. R. (2014). Publication Bias. In *Wiley StatsRef: Statistics Reference Online*. John Wiley. https://doi.org/10.1002/9781118445112.stat07071

Spurzem, L. (2017). *VW 1303 von Wiking in 1:87*. https://de.wikipedia.org/wiki/Modellautomobil#/media/File:Wiking-Modell_VW_1303_(um_1975).JPG

Stigler, S. M. (2016). *The Seven Pillars of Statistical Wisdom*. Harvard University Press.

Ward, A. F., Duke, K., Gneezy, A., & Bos, M. W. (2017). Brain Drain: The Mere Presence of One's Own Smartphone Reduces Available Cognitive Capacity. *Journal of the Association for Consumer Research*, *2*(2), 140–154. https://doi.org/10.1086/691462

Wickham, H. (2023). *Tidy-Data-Sinnbild* [Artwork]. https://r4ds.hadley.nz/data-tidy#fig-tidy-structure