Statistik1

Daten verbildlichen

Sebastian Sauer

Einstieg

Lernziele

- Sie können erläutern, wann und wozu das Visualisieren statistischer Inhalte sinnvoll ist.
- Sie kennen typische Arten von Datendiagrammen.
- Sie können typische Datendiagramme mit R visualisieren.
- Sie können zentrale Ergebnisse aus Datendiagrammen herauslesen.

Benötigte R-Pakete und Daten

Neben `tidyverse` und `easystats` benötigen wir in diesem Kapitel:

```
library(ggpubr)         # Datenvisualisierung
library(ggstatsplot)    # optional, Datenvisualisierung
```

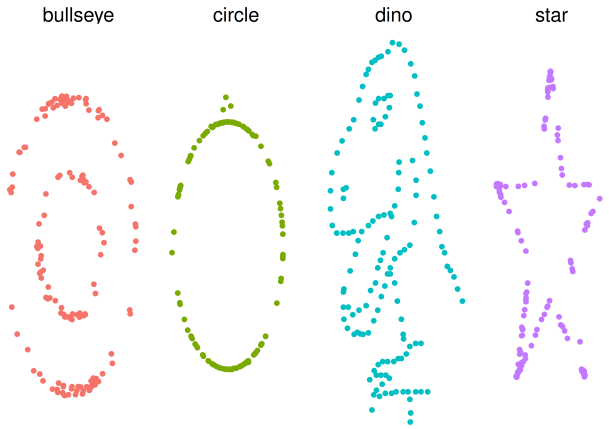
Wir arbeiten wieder mit dem Datensatz `mariokart`.

Wozu das alles?

Ein Bild sagt mehr als 1000 Worte — Datendiagramme helfen, Erkenntnisse aus Daten zu ziehen, ohne mühsam einzelne Zahlen zu vergleichen.

Ein Dino sagt mehr als 1000 Worte

Gleiche Kennwerte, ganz andere Bilder



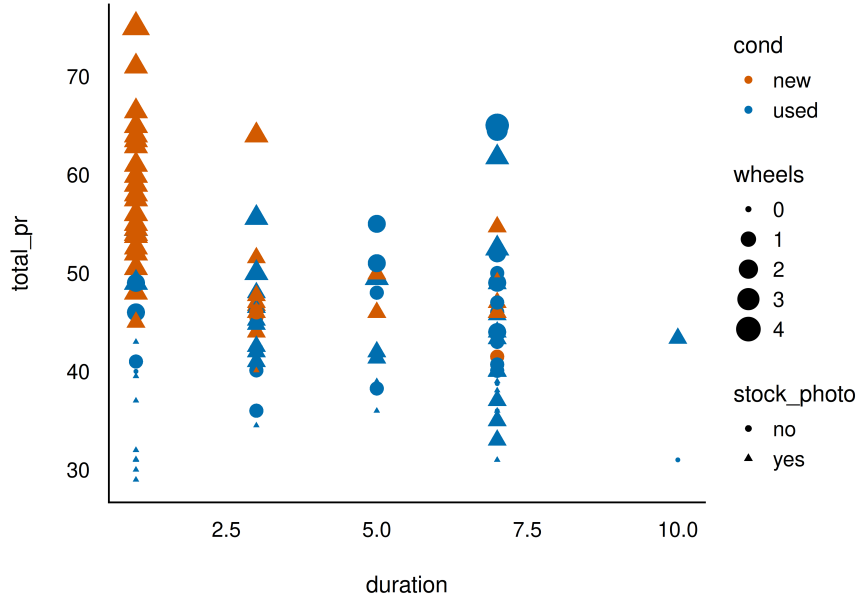
- Verschiedene Datensätze können (nahezu) identische Kennwerte (Mittelwert, Streuung, Korrelation) haben — und trotzdem völlig verschieden aussehen.
- Dasselbe zeigt “Anscombes Quartett”: vier grundverschiedene Streudiagramme mit fast identischen Statistiken.
- Fazit: Eine Visualisierung enthüllt oft, was eine Kennzahl verhüllt.

Definition: Datendiagramm

Definition: Datendiagramm

Ein *Datendiagramm* (kurz: Diagramm) ist ein Diagramm, das Daten und Statistiken zeigt, mit dem Zweck, Erkenntnisse daraus zu ziehen.

Grenzen der Dimensionalität



Ein Bild kann nur eine begrenzte Anzahl an Variablen sinnvoll zeigen — vielleicht vier bis sechs. Bei mehr Variablen brauchen wir Statistik statt (nur) Bilder.

Nomenklatur von Datendiagrammen

Eine kleine Nomenklatur

Erkenntnisziel	qualitativ	quantitativ
Verteilung	Balkendiagramm	Histogramm / Dichtediagramm
Zusammenhang	gefülltes Balkendiagramm	Streudiagramm
Unterschied	gefülltes Balkendiagramm	Boxplot

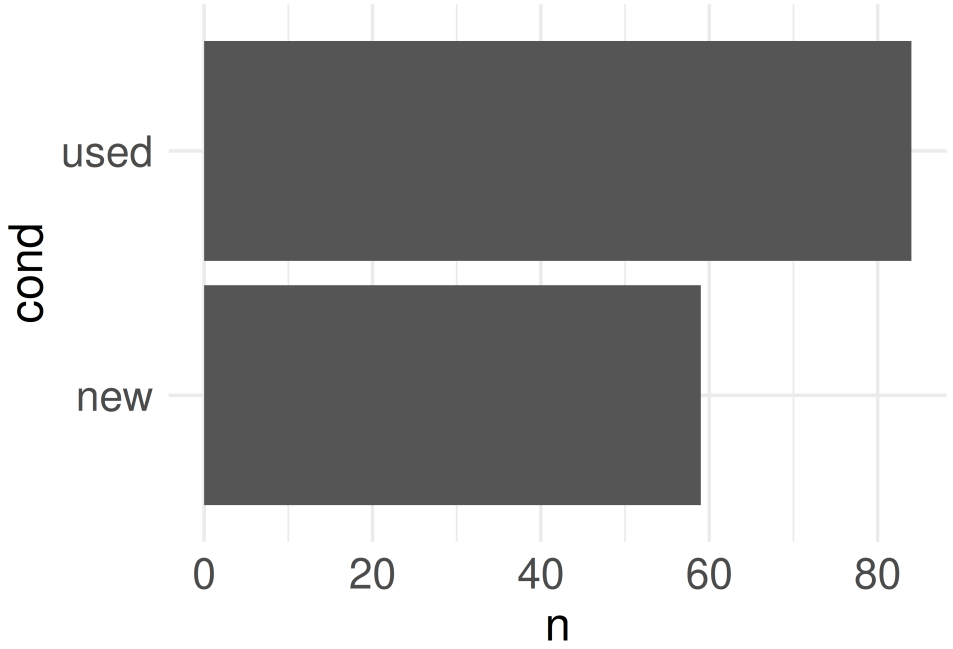
Verteilungen verbildlichen

Definition: Verteilung

Definition: Verteilung

Eine (Häufigkeits-)Verteilung einer Variablen X schlüsselt auf, wie häufig jede Ausprägung von X ist.

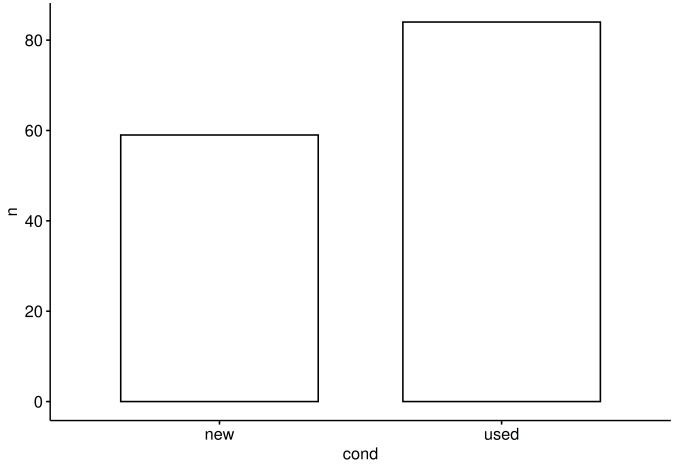
Verteilung einer nominalen Variable: Balkendiagramm



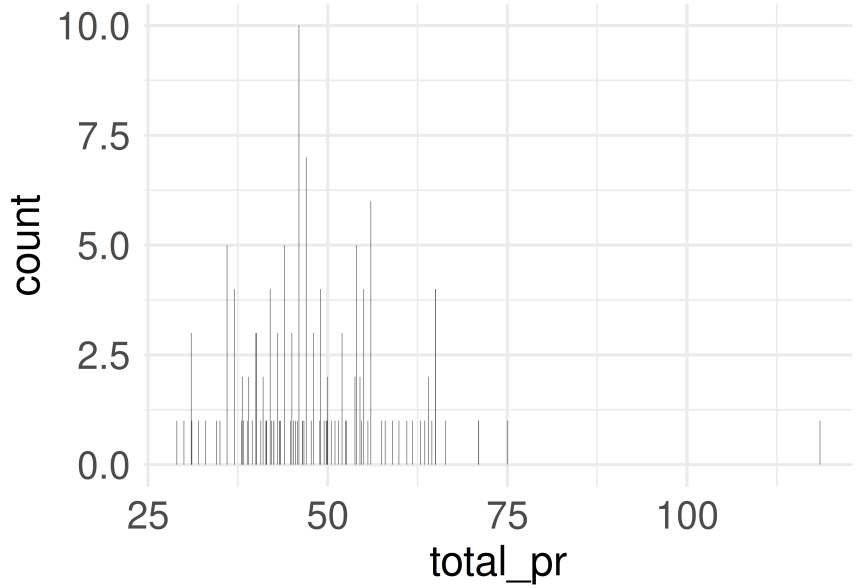
Ein Balkendiagramm zeigt Häufigkeiten von Kategorien als Balken — die Länge ist proportional zur Häufigkeit. Die Ausrichtung (horizontal/vertikal) ist Geschmackssache.

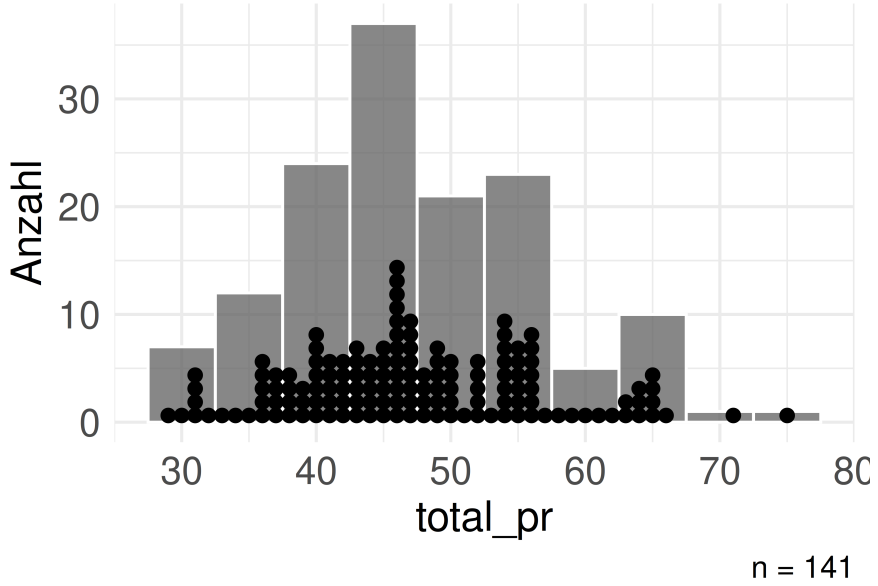
Syntax: Balkendiagramm mit ggpubr

```
1 mariokart %>%
2   count(cond) %>%
3   ggbarplot(x = "cond", y = "n")
```



Verteilung einer quantitativen Variable





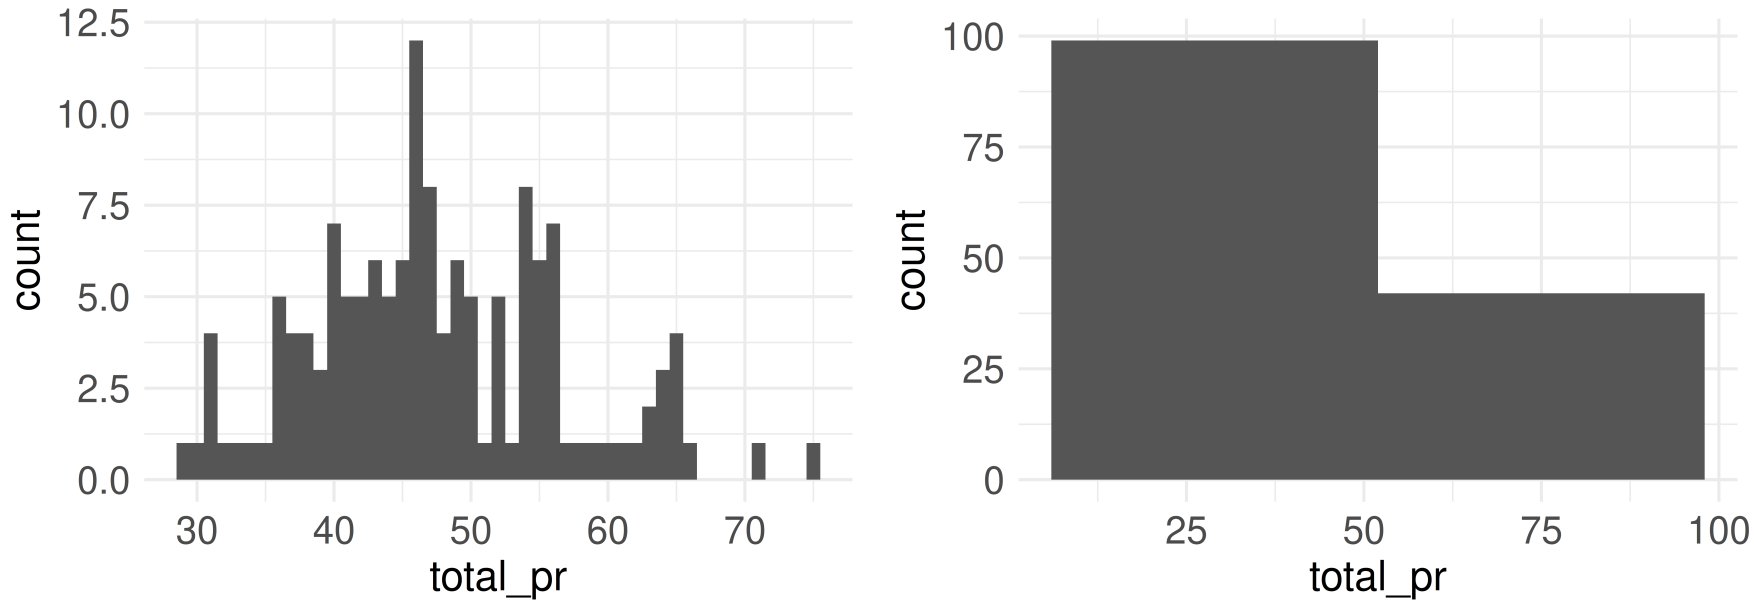
Bei vielen Ausprägungen ist ein Balkendiagramm unübersichtlich. Lösung: Werte in Gruppen (Klassen) zusammenfassen — das ergibt ein **Histogramm**.

Definition: Histogramm

Definition: Histogramm

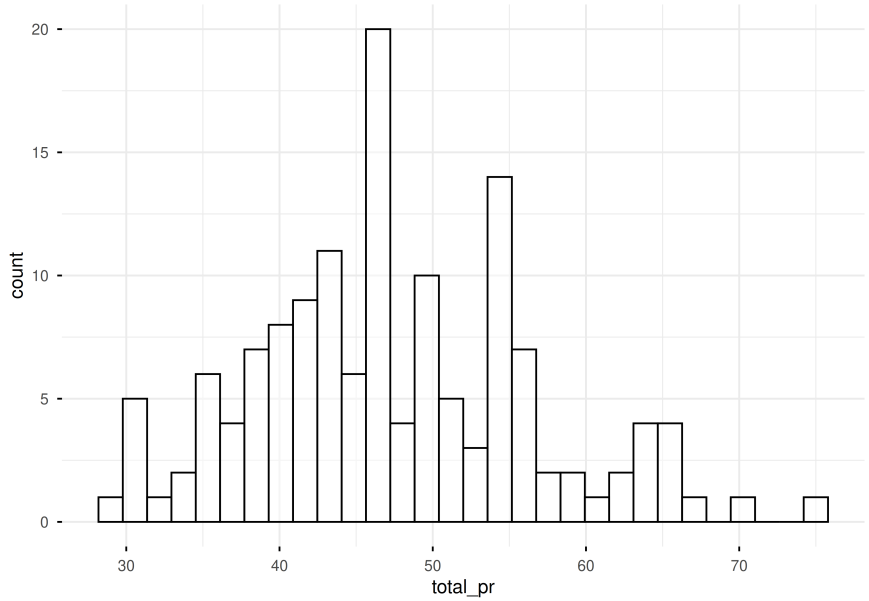
Ein Histogramm ist ein Diagramm zur Darstellung der Häufigkeitsverteilung einer quantitativen Variablen. Die Daten werden in Klassen eingeteilt, die durch Balken dargestellt werden; die Balkenhöhe zeigt die Häufigkeit pro Klasse.

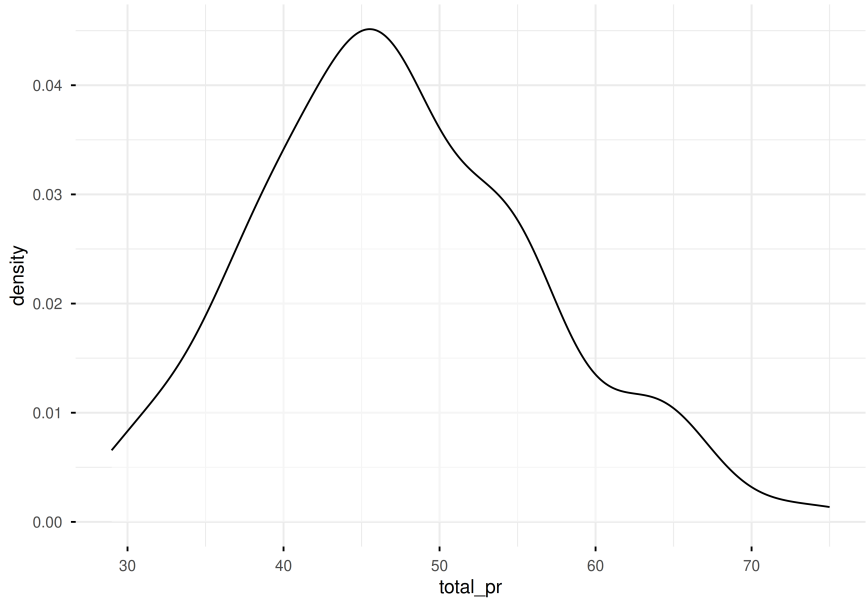
Wie viele Balken? Nicht zu viele, nicht zu wenige



Es gibt keine feste Regel für die Balkenanzahl — nur: nicht zu grob, nicht zu fein.

Histogramm vs. Dichtediagramm

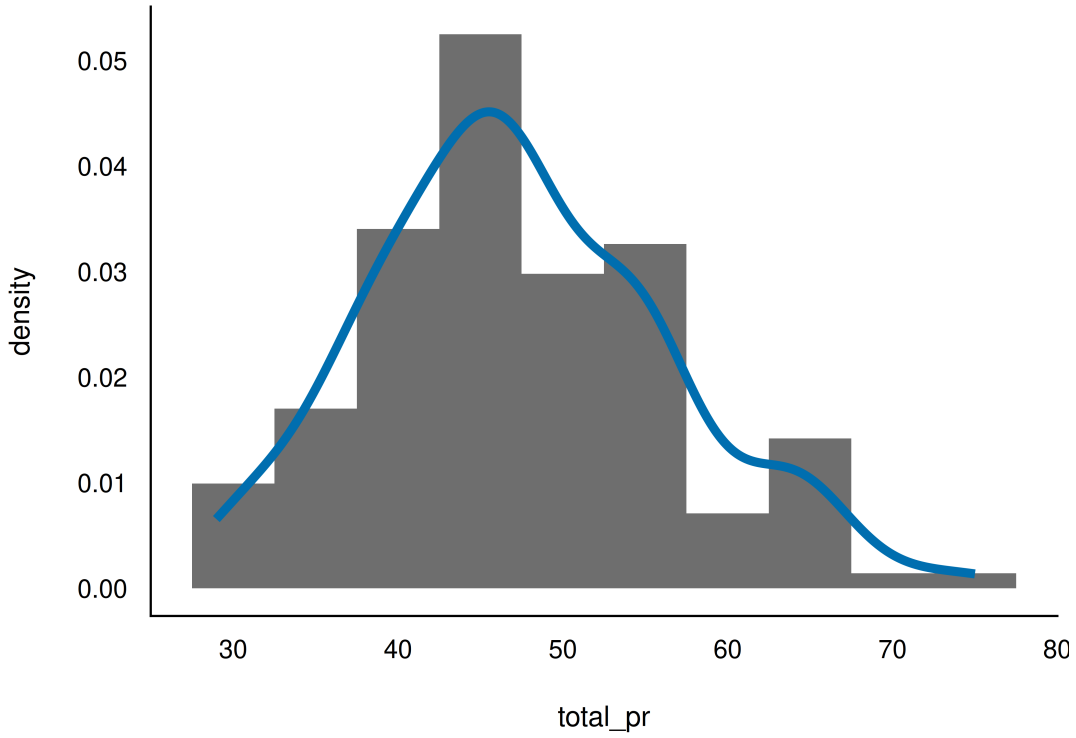




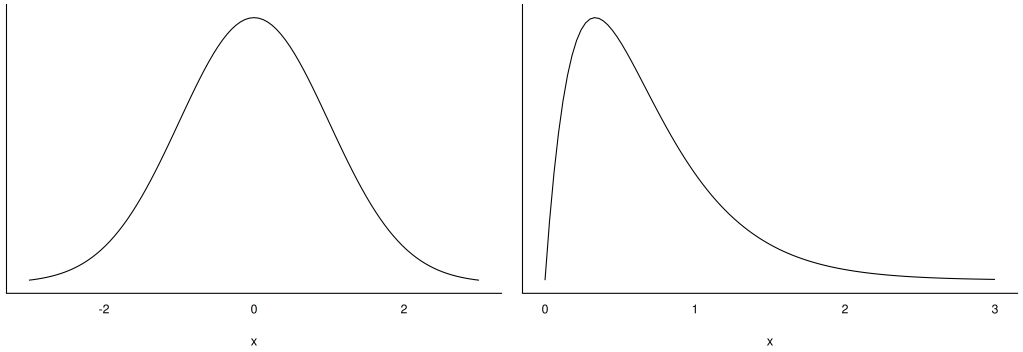
Definition: Dichtediagramm

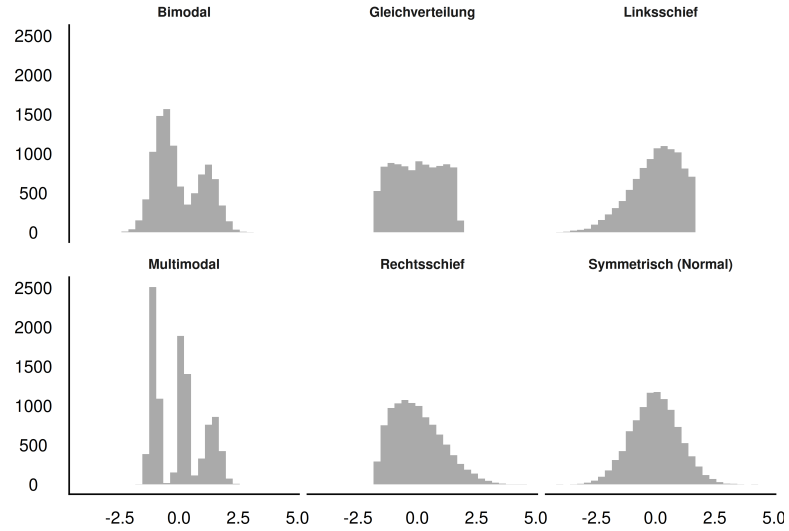
Ein Dichtediagramm visualisiert die Verteilung einer stetigen Variablen — geglättet, sodass Rauschen weniger stört als beim Histogramm.

Histogramm + Dichtelinie kombiniert



Verteilungsformen





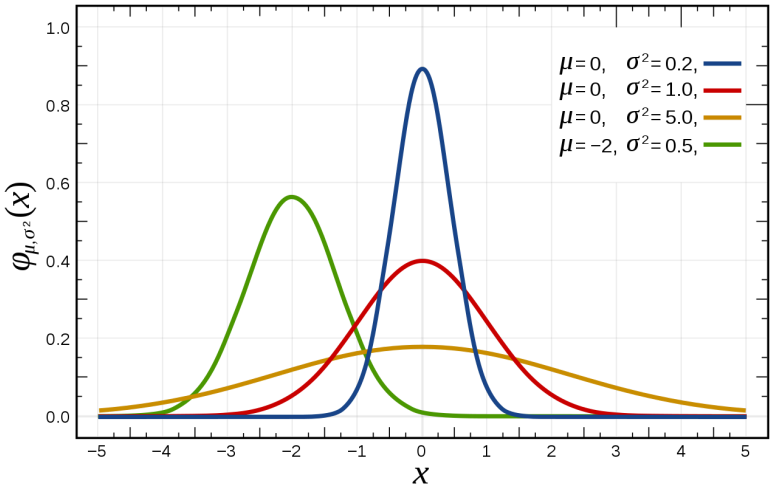
Spezialfall Normalverteilung

Definition: Normalverteilung

Definition: Normalverteilung

Normalverteilungen haben eine charakteristische, symmetrische Glockenform. Sie unterscheiden sich in Mittelwert μ und Streuung σ — diese beiden Parameter bestimmen den gesamten Kurvenverlauf.

Kurzschreibweise: $X \sim \mathcal{N}(\mu, \sigma)$

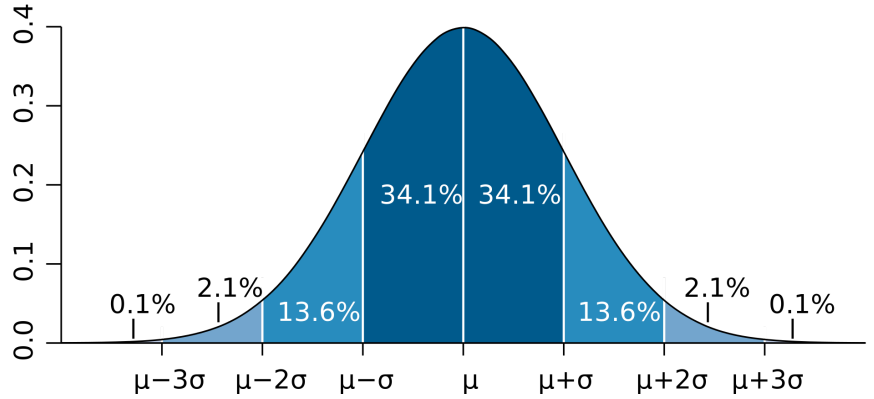


Normalverteilungen mit verschiedenen Mittelwerten und Streuungen (Inductiveload, 2008)

Beispiele normalverteilter Variablen

Körpergröße, IQ-Werte, Prüfungsergebnisse, Messfehler, Lebensdauer von Glühbirnen, Gewicht von Brotlaiben, Milchproduktion von Kühen …

Fläche unter der Kurve



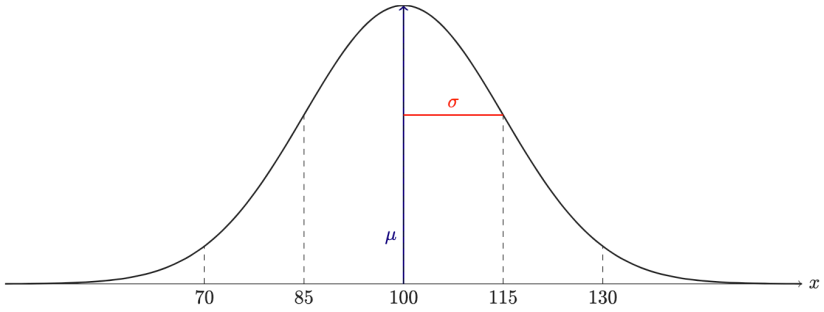
Flächeninhalte (Wahrscheinlichkeitsmasse) einer Normalverteilung (Ainali, 2007)

Die **68-95-99,7-Prozentregel**:

- $68\,\%$ im Bereich $\mu \pm 1 \cdot \sigma$
- $95\,\%$ im Bereich $\mu \pm 2 \cdot \sigma$
- $99.7\,\%$ im Bereich $\mu \pm 3 \cdot \sigma$

Beispiel: IQ-Verteilung

$IQ \sim \mathcal{N}(100, 15)$



Entstehung einer Normalverteilung

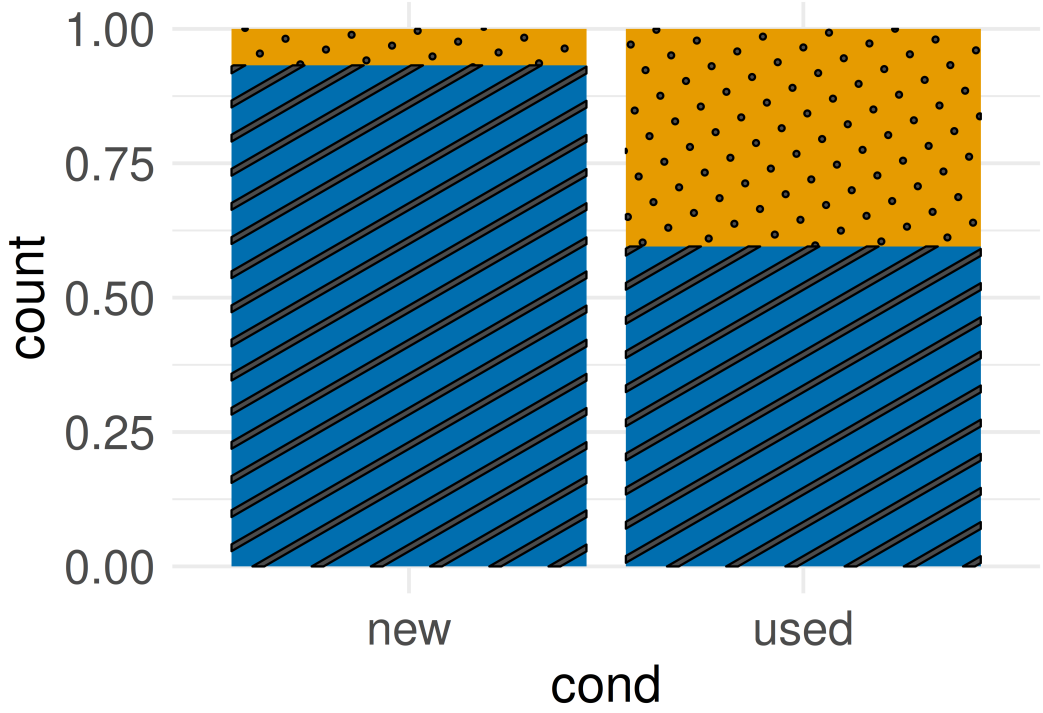
Definition: Entstehung einer Normalverteilung

Wenn sich eine Variable X als Summe mehrerer, unabhängiger, etwa gleich starker Summanden ergibt, tendiert X dazu, normalverteilt zu sein.

Anschaulich zeigt das Galton-Brett, wie aus vielen kleinen Zufallsereignissen eine Glockenkurve entsteht.

Zusammenhänge verbildlichen

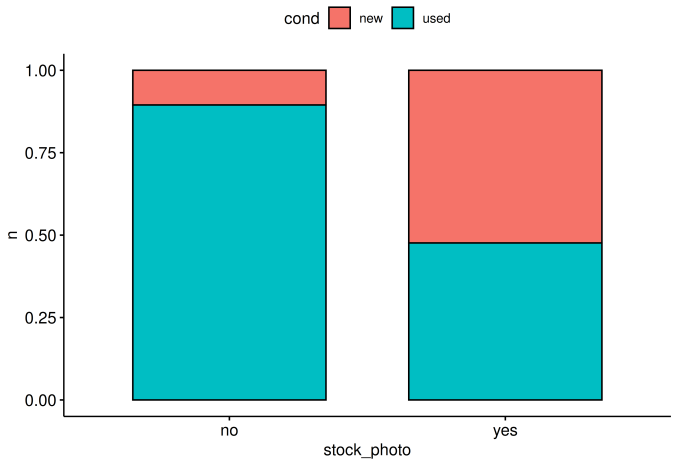
Zusammenhang nominaler Variablen



Bei neuen Spielen war fast immer ein Foto dabei; bei gebrauchten nur bei gut der Hälfte — ein Zusammenhang zwischen `cond` und `stock_photo`.

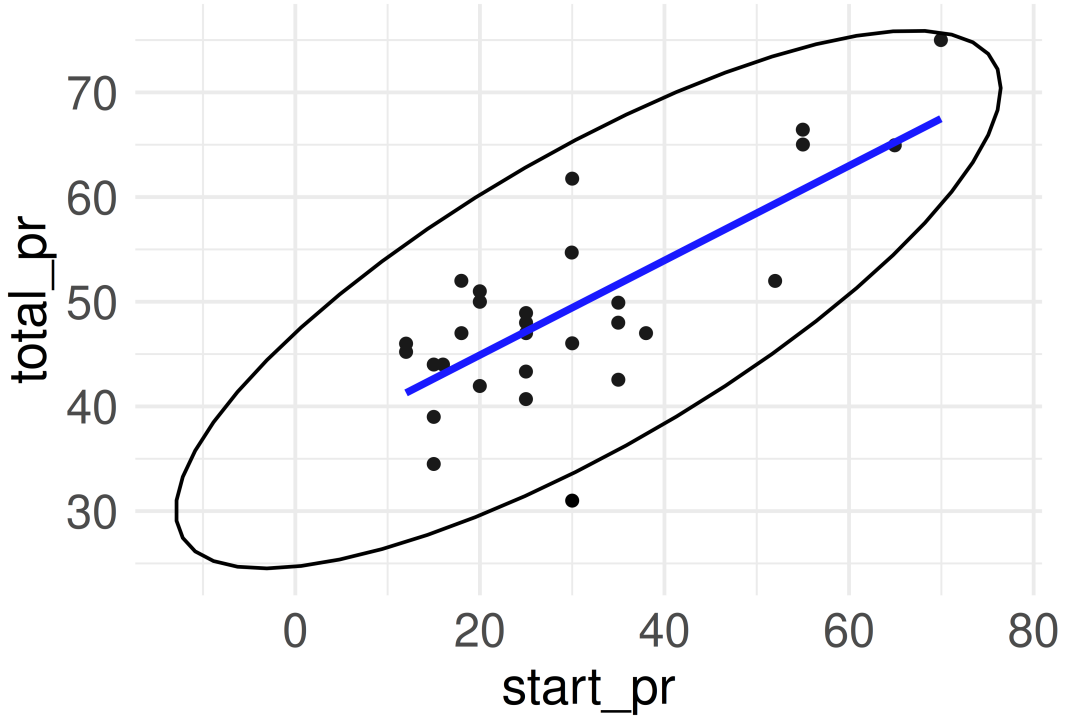
Gefüllte Balkendiagramme

```
mariokart %>%
  count(stock_photo, cond) %>%
  ggbarplot(x = "stock_photo", y = "n", fill = "cond",
            position = position_fill())  # aus dem Paket ggpubr
```



Geeignet, wenn (mindestens) eine der beiden Variablen nur zwei Ausprägungen hat.

Zusammenhang bei metrischen Variablen: Streudiagramm



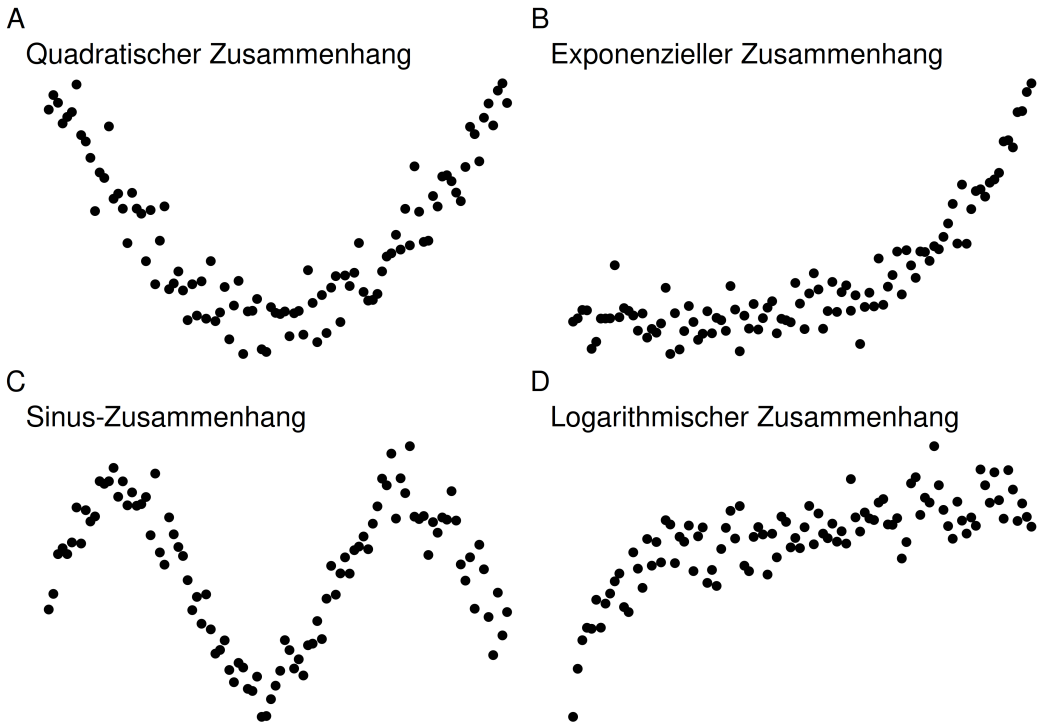
Die Trendgerade (Regressionsgerade) zeigt Richtung des Zusammenhangs; die Ellipse zeigt, wie eng die Daten um sie streuen.

Definition: Linearer Zusammenhang

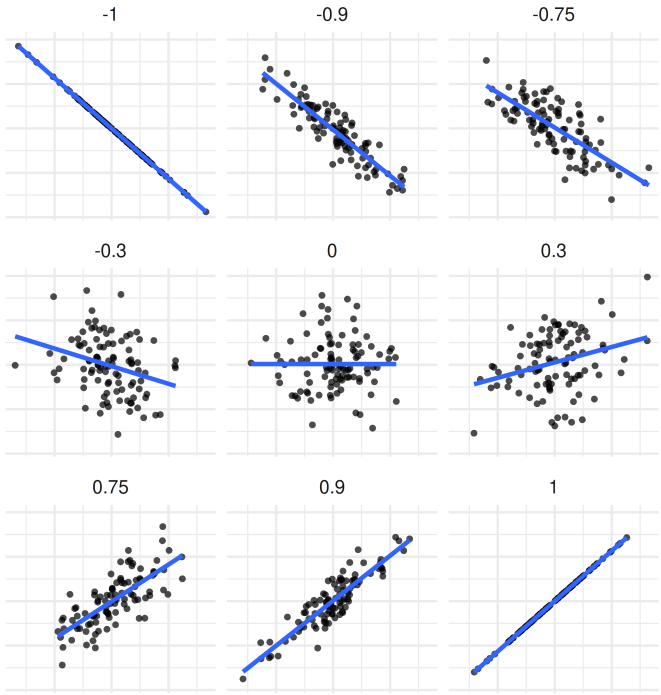
Definition: Linearer Zusammenhang

Lässt sich die Beziehung zweier Variablen gut mit einer Geraden beschreiben, spricht man von einem linearen Zusammenhang. *Gleichsinnige* (positive) Zusammenhänge zeigen aufsteigende Trendgeraden ↗; *gegensinnige* (negative) zeigen absteigende Trendgeraden ↘.

Auch nicht-lineare Zusammenhänge gibt es



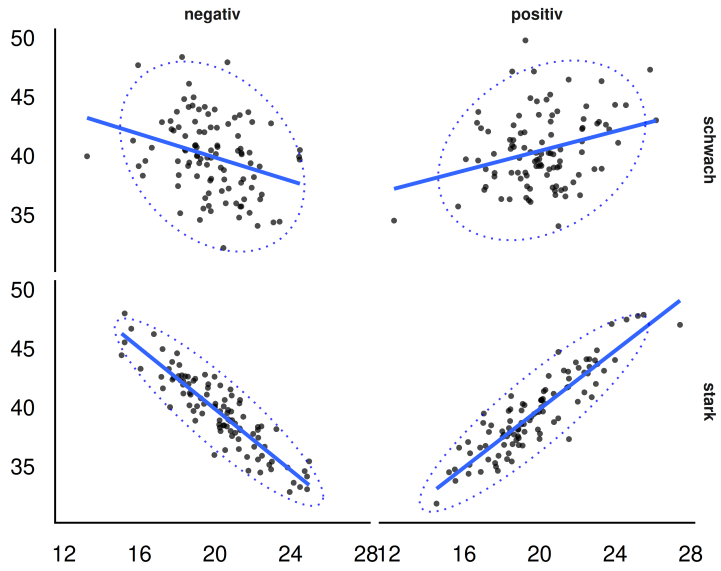
Stärke und Richtung von Zusammenhängen



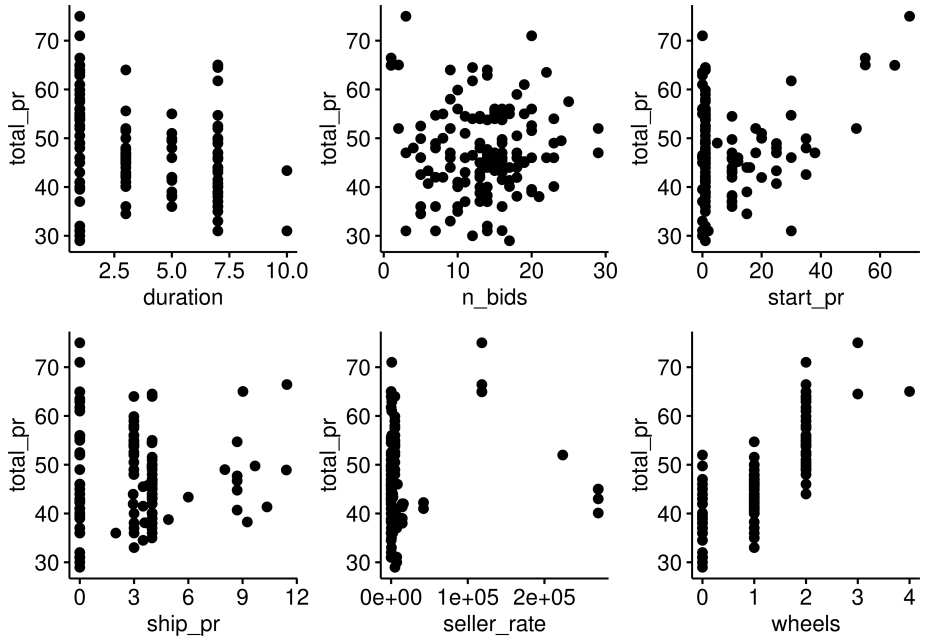
Schmale Ellipsen (“Baguette”) = starker Zusammenhang; breite Ellipsen (“Torte”) = schwacher Zusammenhang.

Faustregeln für den Korrelationskoeffizienten

- $r \approx 0$: kein Zusammenhang
- $r \pm .1$: schwacher Zusammenhang
- $r \pm .3$: mittlerer Zusammenhang
- $r \pm .5$: starker Zusammenhang
- $r = 1$: perfekter Zusammenhang



Mehrere Zusammenhänge auf einen Blick



Mit `map()` bauen wir für jede Variable ein `ggscatter()`-Diagramm gegen die Zielvariable `total_pr` und fügen alle mit `ggarrange()` zu einem Panel zusammen — `start_pr` und `wheels` hängen am stärksten mit `total_pr` zusammen.

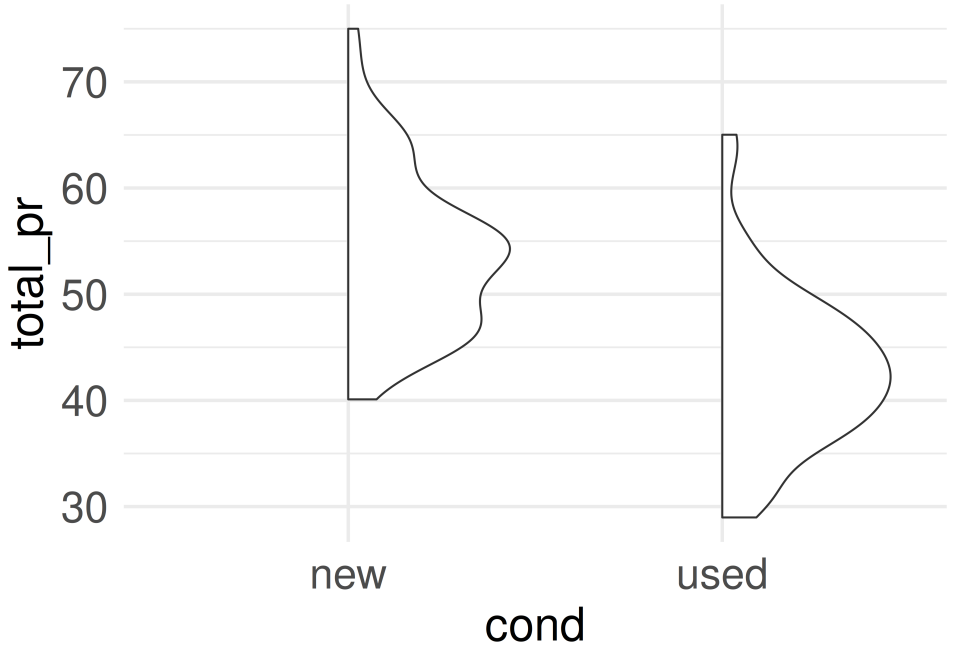
Unterschiede verbildlichen

Unterschiede bei nominalen Variablen

Für nominale Variablen eignen sich Balkendiagramme sowohl für Zusammenhänge als auch für Unterschiede — beides ist letztlich dieselbe Fragestellung, nur anders formuliert.

Tortendiagramme sind dagegen ungeeignet: Flächenvergleiche sind für das Auge schwer.

Unterschiede bei quantitativen Variablen: Boxplot

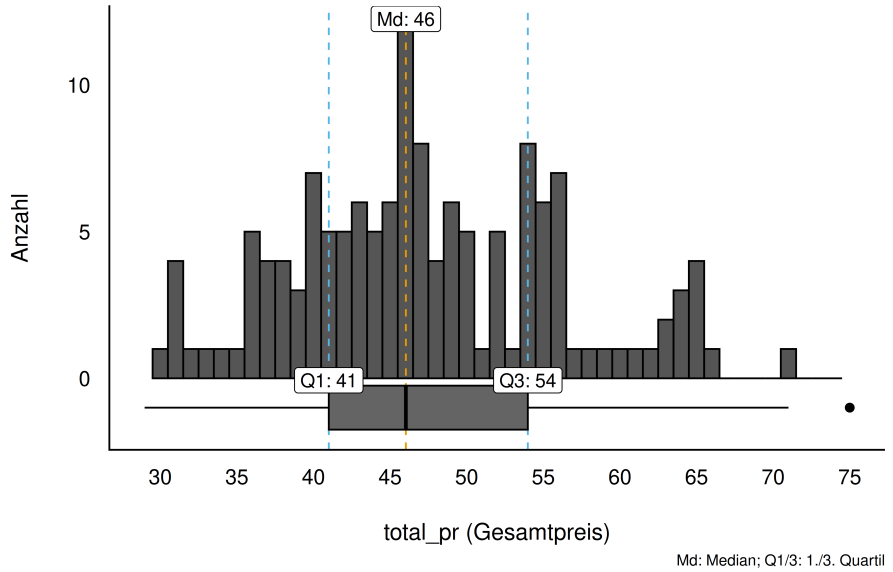


Der Boxplot vereinfacht die Verteilungsdarstellung — kompakter als ein Histogramm, aber mit weniger Detail.

Definition: Boxplot

Definition: Boxplot

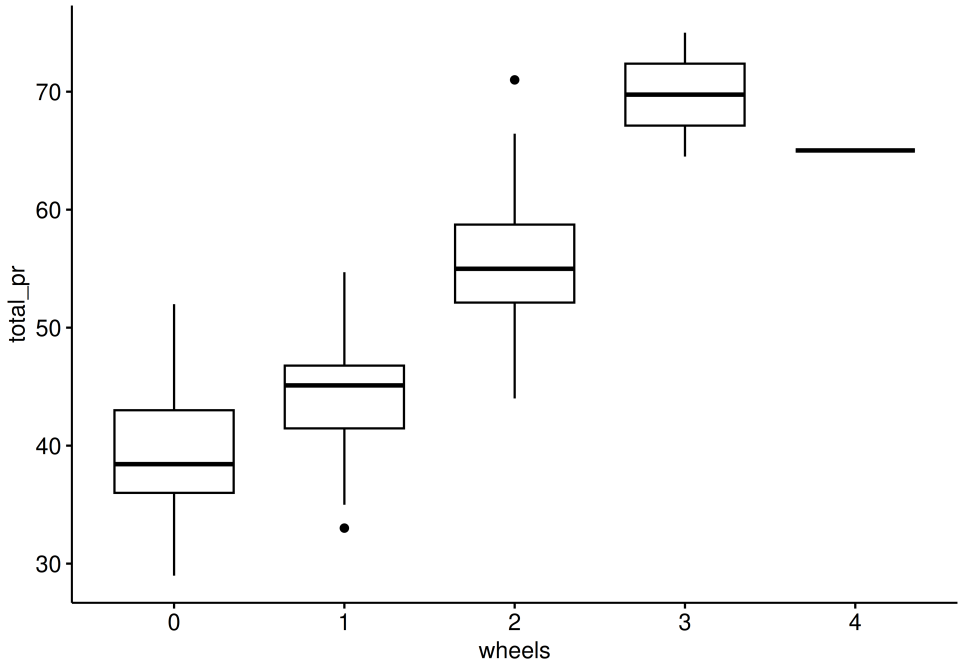
Der Boxplot ist eine Vereinfachung bzw. Zusammenfassung eines Histogramms. Damit stellt er ebenfalls eine Verteilung (einer metrischen Variablen) dar.



Anatomie des Boxplots

1. **Dicker Strich**: Median der Verteilung.
2. **Enden der Box**: 1. und 3. Quartil — die Breite ist der *Interquartilsabstand* (IQR).
3. **Antennen**: Streuung der äußeren 25 % (links/rechts), begrenzt auf das 1,5-fache der Boxlänge.
4. **Einzelne Punkte**: Extremwerte außerhalb der Antennen.
5. Median mittig in der Box + gleich lange Antennen → Verteilung symmetrisch; sonst schief.

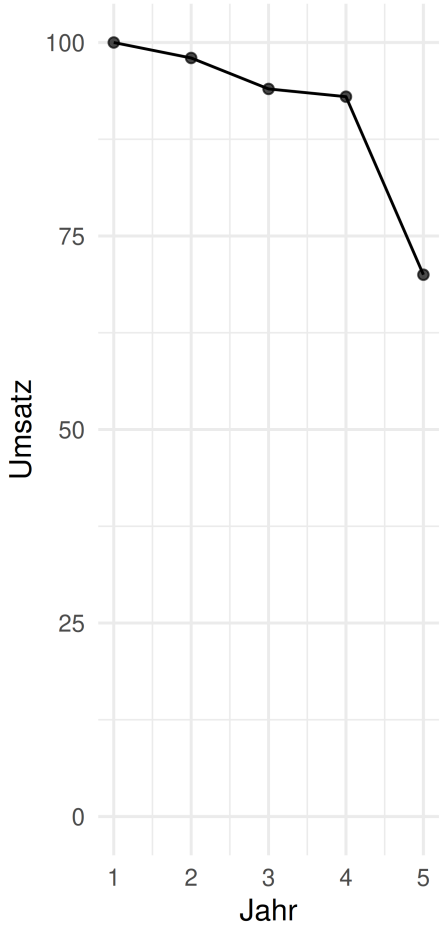
Boxplot: metrisch vs. nominal gruppiert



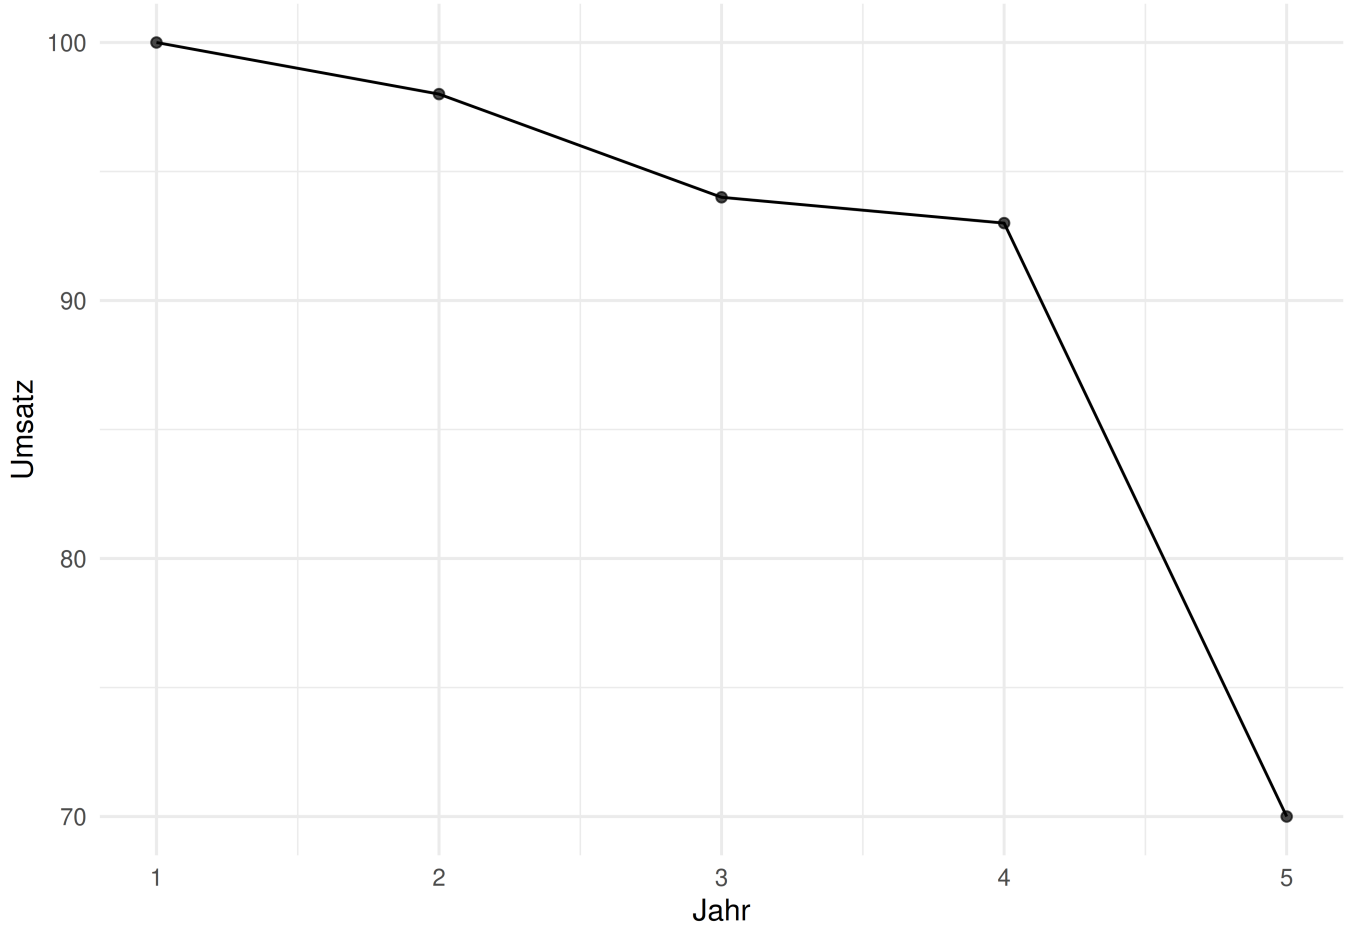
`factor(wheels)` erzwingt, dass jeder Wert (0, 1, 2, 3, 4) als eigene Gruppe behandelt wird — sonst gruppiert R metrische Variablen automatisch (und nicht immer sinnvoll).

So lügt man mit Statistik

Achsen stauchen und strecken



Die Y-Achse abschneiden



Scheinkorrelationen als Kausalität verkaufen

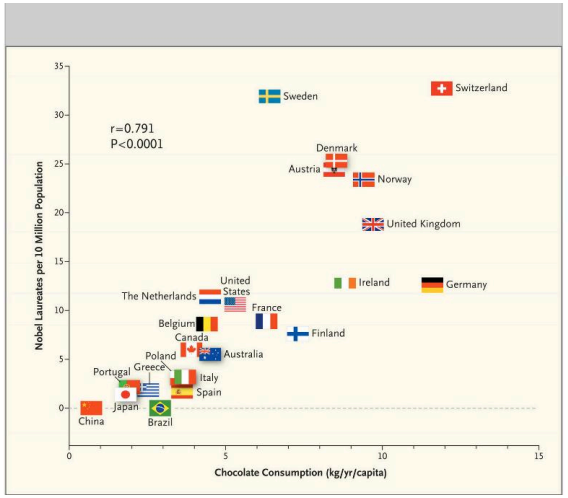


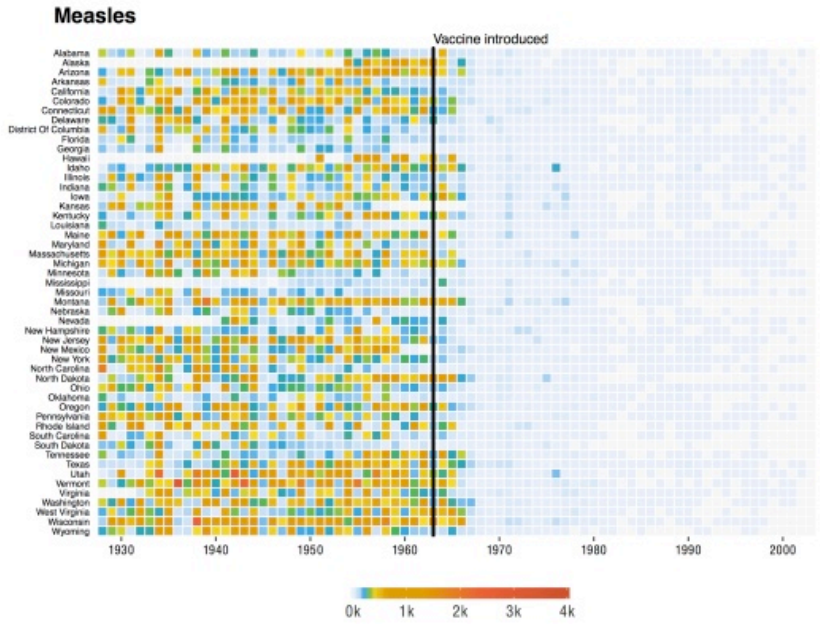
Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

Schokoladenkonsum und Nobelpreise (Messerli, 2012)

Schokoladenkonsum hängt mit der Anzahl der Nobelpreise (pro Land) zusammen — aber nicht ursächlich. Eine Drittvariable (z. B. allgemeiner Entwicklungsstand) erklärt vermutlich beides gleichzeitig.

Praxisbezug

Die Stärke von Datendiagrammen



Häufigkeit von Masern vor und nach Einführung der Impfung (Moore, 2015)

Ein Diagramm kann eine Botschaft (hier: Wirksamkeit der Impfung) auf einen Blick vermitteln — deutlich eindrücklicher als eine Tabelle mit Zahlen.

Tortendiagramme bleiben aber meist eine schlechte Wahl.

Zusammenfassung

- Datendiagramme decken auf, was reine Kennzahlen verbergen (Dino-Datensatz, Anscombes Quartett)
- **Verteilung**: Balkendiagramm (nominal), Histogramm/Dichtediagramm (quantitativ) — bei Normalverteilung: μ und σ bestimmen alles
- **Zusammenhang**: gefülltes Balkendiagramm (nominal), Streudiagramm (metrisch) — Stärke via Ellipsenform/Korrelation
- **Unterschied**: Boxplot fasst eine Verteilung kompakt zusammen (Median, Quartile, Antennen, Extremwerte)
- Vorsicht: Diagramme lassen sich manipulieren (gestauchte Achsen, abgeschnittene Y-Achse, Scheinkorrelationen)

Literaturhinweise

- Wickham (2016) — das Standardwerk zu `ggplot2`, kostenfrei online
- Wilke (2019) — hervorragender, praxisnaher Überblick über Datenvisualisierung mit R
- Fisher & Meyer (2018) — verwandte Perspektive auf gutes Visualisieren

Referenzen

Ainali. (2007). *Standard Deviation Diagram Micro* [Artwork]. https://commons.wikimedia.org/w/index.php?curid=3141713

Fisher, D., & Meyer, M. (2018). *Making Data Visual: A Practical Guide to Using Visualization for Insight*. O'Reilly.

Inductiveload. (2008). *Normal Distribution PDF* [Artwork]. https://commons.wikimedia.org/wiki/File:Normal_Distribution_PDF.svg

Messerli, F. H. (2012). Chocolate Consumption, Cognitive Function, and Nobel Laureates. *New England Journal of Medicine*, *367*(16), 1562–1564. https://doi.org/10.1056/NEJMon1211064

Moore, B. (2015, April 9). *Recreating the Vaccination Heatmaps in R*. Benomics. https://benjaminlmoore.wordpress.com/2015/04/09/recreating-the-vaccination-heatmaps-in-r/

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. https://ggplot2.tidyverse.org

Wilke, C. (2019). *Fundamentals of Data Visualization: A Primer on Making Informative and Compelling Figures*. O'Reilly. https://clauswilke.com/dataviz/