Statistik1

Modellgüte

Sebastian Sauer

Einstieg

Lernziele

- Sie kennen gängige Maße der Streuung einer Stichprobe und können diese definieren und anhand von Beispielen erläutern.
- Sie können gängige Maße der Streuung einer Stichprobe mit R berechnen.
- Sie können die Bedeutung von Streuung für die Güte eines Modells erläutern.

Die Schlankheitspille von Prof. Weiss-Ois



Was er sagt: “Meine Pille reduziert das Gewicht im Schnitt um 1 kg!”

Was er NICHT sagt: Die Werte streuten um 10 kg um den Mittelwert.

Wie sehr die Werte eines Modells streuen, ist eine wichtige Information — bei der Pille kann es sein, dass Sie 10 kg *zunehmen*.

Wie man seine Kuh über den Fluss bringt

Fritz will mit seiner Kuh einen Fluss überqueren. Er fragt Karla, ob der Fluss tief ist.

> Karla: Nö, im Schnitt nur einen Meter.

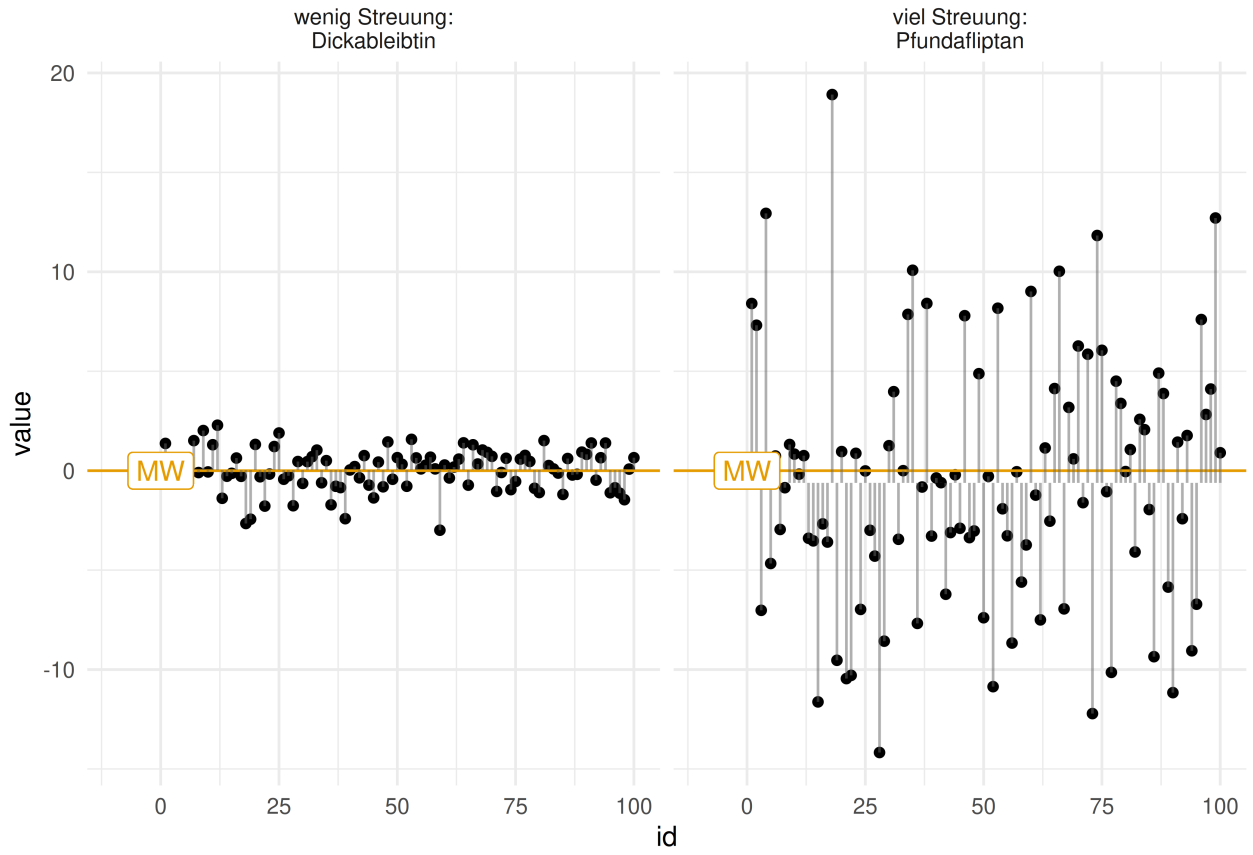
Fritz führt seine Kuh durch den Fluss — die Kuh ertrinkt.

Wichtig

Die Streuung der Daten zu kennen, ist eine wesentliche Information — ein Lagemaß (wie der Mittelwert) allein reicht nicht.

Woran erkennt man ein gutes Modell?

Wenig vs. viel Streuung



Bei wenig Streuung liegen beobachtete Werte (y) nah an den Modellwerten ($\hat{y}$) — die Abweichungen $e = y - \hat{y}$ sind gering.

Woran erkennt man ein gutes Modell?

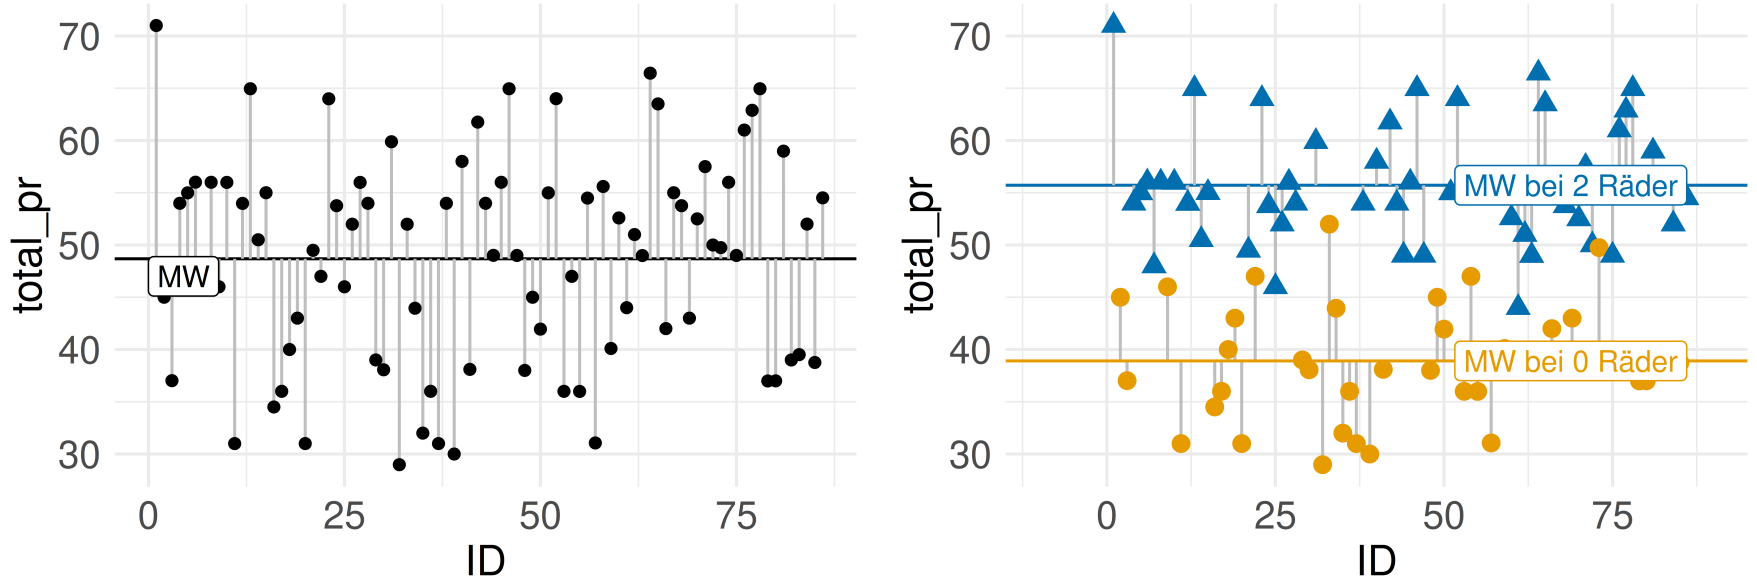
Modellgüte = Präzision des Modells

Wir wollen ein präzises Modell, also kurze Fehlerbalken: Das Modell soll die Daten gut erklären, also wenig vom tatsächlichen Wert abweichen.

Wichtig

Ein Modell ohne Angabe der Modellgüte (Präzision der Schätzung) ist wenig nütze.

Ein komplexeres Modell reduziert die Streuung



Innerhalb der Gruppen (0 vs. 2 Lenkräder) sind die Fehlerbalken im Schnitt kürzer als im ungruppierten Modell.

Streuungsmaße

Definition: Streuungsmaß

Definition: Streuungsmaß

Ein Streuungsmaß quantifiziert die Variabilität (Unterschiedlichkeit, Streuung) eines Merkmals.

Definition: Spannweite

Definition: Spannweite

Die Spannweite (Range) R ist die Differenz von größtem und kleinstem Wert eines Merkmals X: $R := X_{max} - X_{min}$.

Beispiel: Werte 1, 23, 42, 100 → $R = 100 - 1 = 99$.

Die Spannweite ist nicht robust gegenüber Extremwerten und sollte nur eingeschränkt verwendet werden.

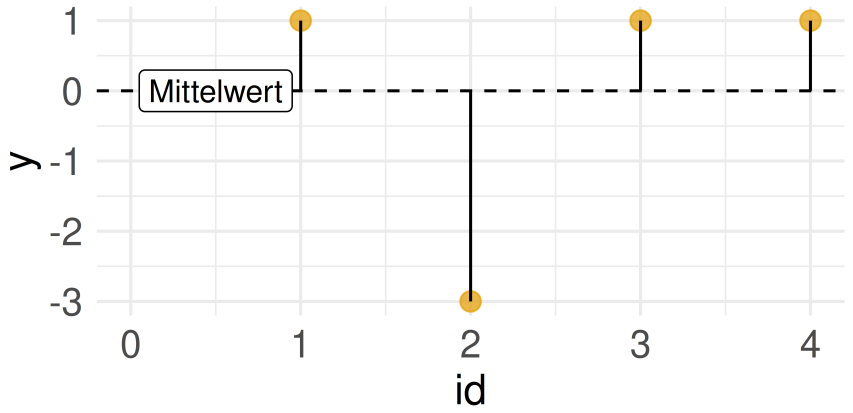
Der mittlere Abweichungsbalken (MAE)

Legt man alle Abweichungsbalken e aneinander und teilt durch die Anzahl n, erhält man den “mittleren Abweichungsbalken” $\bar{e}$ — die *Mittlere Absolutabweichung* (MAE, MAA).

Definition: Mittlere Absolutabweichung

$$\mathrm{MAE} := \frac{\sum_{i=1}^{n} |y_i - \bar{y}|}{n} = \frac{\sum_{i=1}^{n} |e_i|}{n} = \bar{e}$$

MAE: Beispiel & R-Berechnung



$$MAE = \frac{1+|-3|+1+1}{4} = 6/4 = 1.5$$

Den Mittelwert kann man als lineares Modell (Gerade) auffassen: `lm(y ~ 1, data = d)`.

```r
lm_ohne_x_var <- lm(y ~ 1, data = d)
mae(lm_ohne_x_var)  # aus dem Paket easystats
```

Der Interquartilsabstand (IQR)

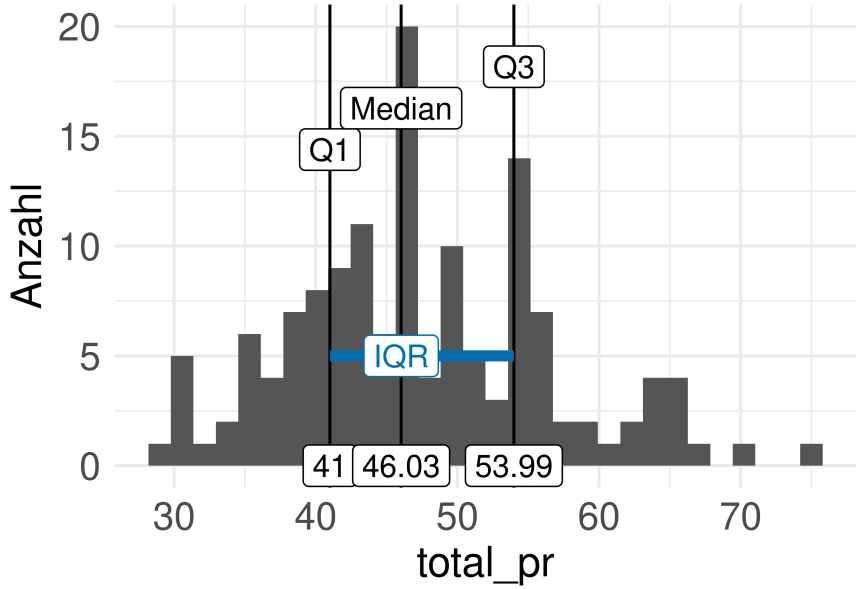
Definition: Interquartilsabstand

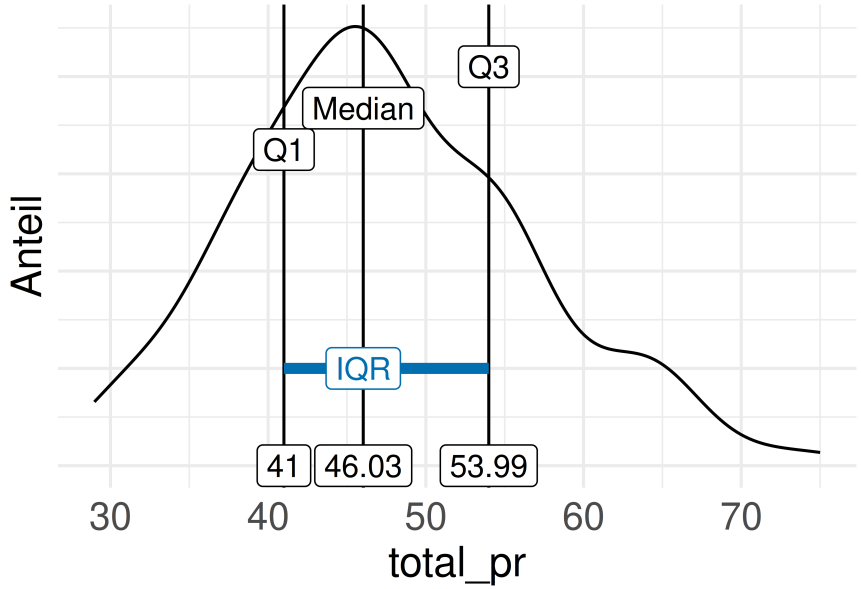
$$IQR := Q_3 - Q_1$$

Der IQR ist robuster als MAA, Varianz und Standardabweichung — er baut nicht auf dem Mittelwert auf.

Beispiel: Q1 = 1.65 m, Q3 = 1.75 m →
$IQR = 1.75\,m - 1.65\,m = 0.10\,m$ (10 cm).

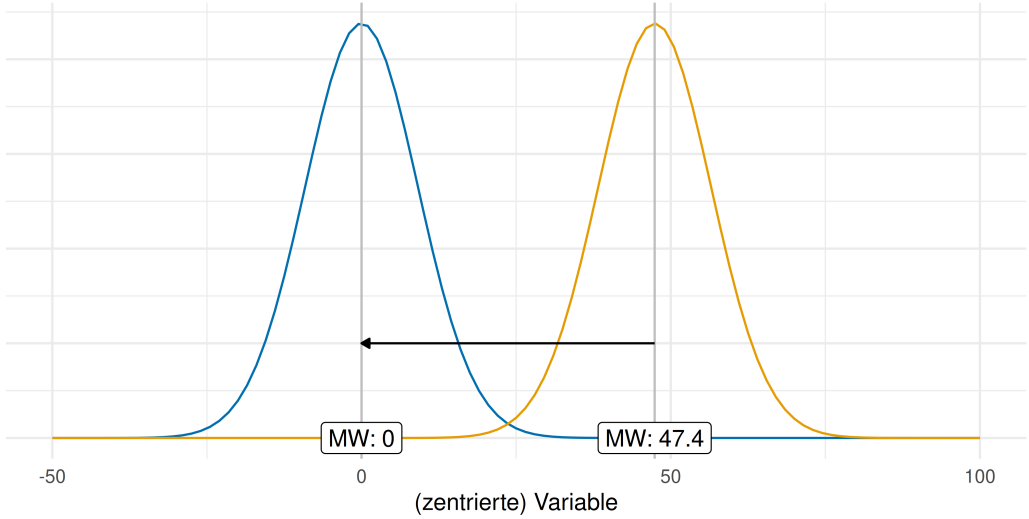
IQR am Beispiel Mariokart





Streuungsmaße für Normalverteilungen

Eine Normalverteilung lässt sich komplett über *Mittelwert* und *Standardabweichung* beschreiben.



Eine Konstante addieren “verschiebt den Berg”, ohne die Form zu verändern.

Definition: Varianz

Die Varianz ist der mittlere quadrierte Abstand jedes Werts vom Mittelwert.

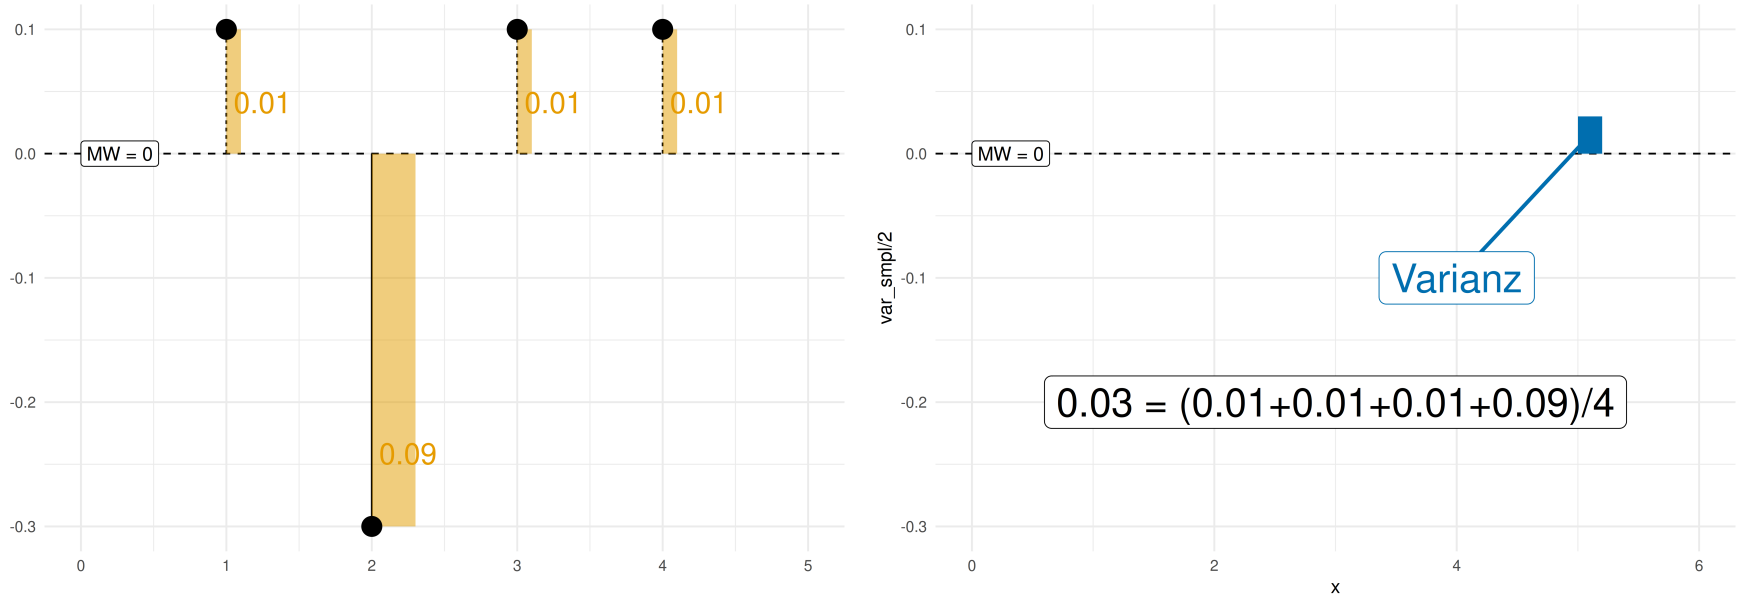
Definition: Varianz

$$s^2 := \frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y})^2 = \frac{1}{n}\sum_{i=1}^{n} e_i^2$$

Sie entspricht dem *Mean Squared Error* (MSE) eines Modells:

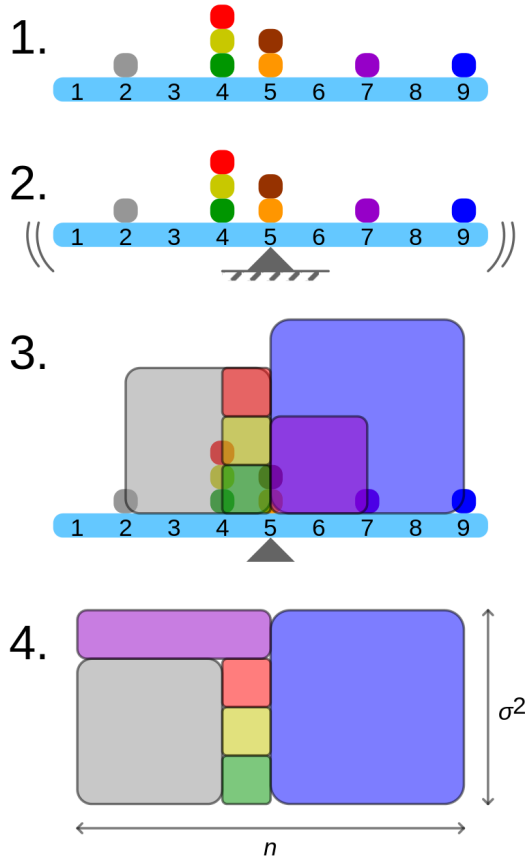
$$MSE := \frac{1}{n}\sum_{i=1}^{N}(y_i - \hat{y})^2$$

Varianz als “mittlerer Quadratfehler”



Die Varianz fasst die typische *quadrierte* Abweichung der Beobachtungen vom Mittelwert in eine Zahl.

Varianz geometrisch



Varianz als Fläche eines Rechtecks aus umgeformten Abweichungsquadraten (Cmglee, 2015)

Man ordnet die Abweichungsquadrate zu einem Rechteck mit Seitenlängen n und σ^2.

Die Standardabweichung

Definition: Standardabweichung

Die Standardabweichung (SD, s, σ) ist die Quadratwurzel der Varianz: $s := \sqrt{s^2}$

Aus Modellierungssicht ist die SD die Wurzel des MSE — man nennt sie *Root Mean Squared Error*: $RMSE := \sqrt{MSE}$

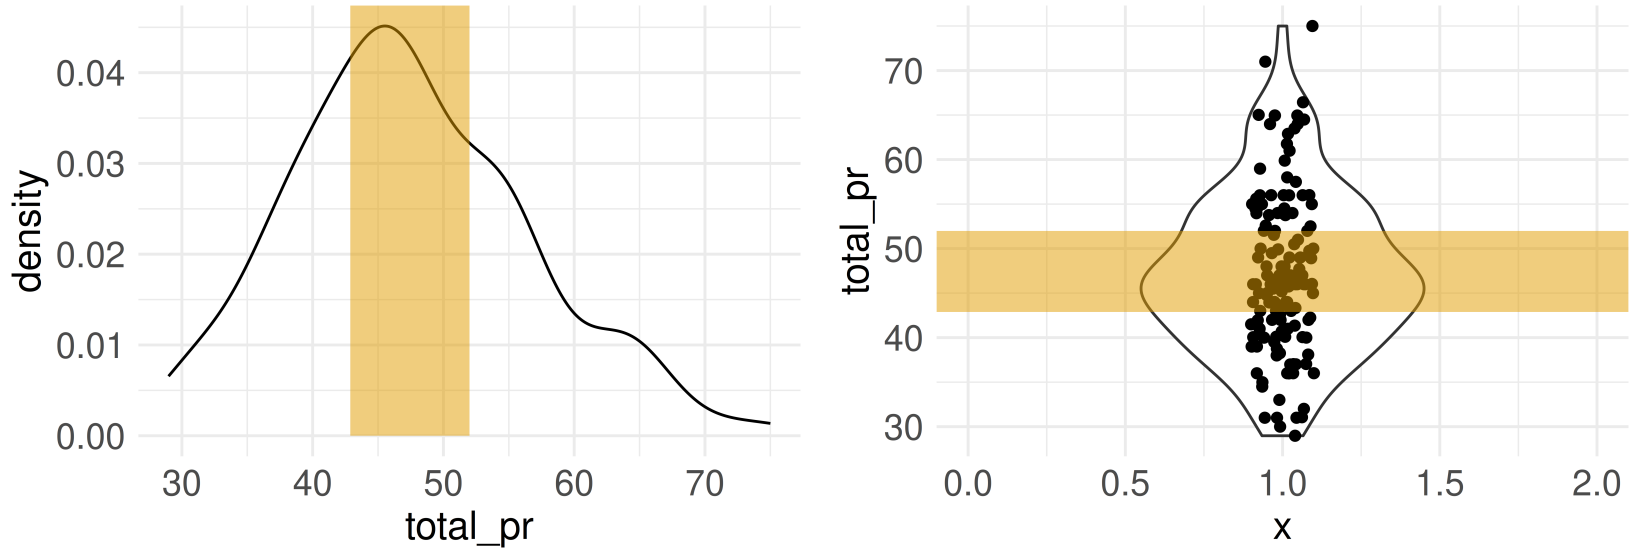
Hinweis

Die SD ist i. d. R. *un*gleich zur MAE, aber (fast) gleich zur RMSE.

Streuungsmaße im Vergleich: Mariokart

Modellgüte des Mittelwerts anhand der Streuung im Verkaufspreis (`mariokart`, Extremwerte entfernt):

```
m_summ <- mariokart_no_extreme %>%
  summarise(
    pr_mw = mean(total_pr), pr_iqr = IQR(total_pr),
    pr_maa = mean(abs(total_pr - mean(total_pr))),
    pr_var = var(total_pr), pr_sd = sd(total_pr))
```



Streuung als Modellfehler

Nullmodell und Modellgüte in R

Fassen wir den Mittelwert als Punktmodell des Verkaufspreises auf, sind die Streuungskennwerte zugleich Kennwerte der Modellgüte. Ein Modell ohne UV heißt *Nullmodell*.

```
1 lm_mario_ohne_x_var <- lm(total_pr ~ 1, data = mariokart)
2
3 mae(lm_mario_ohne_x_var)   # Mean absolute error
4 mse(lm_mario_ohne_x_var)   # Mean squared error
5 rmse(lm_mario_ohne_x_var)  # Root mean squared error
```

Ein komplexeres Modell (z. B. `total_pr ~ wheels`) senkt i. d. R. den MAE gegenüber dem Nullmodell.

Die z-Transformation

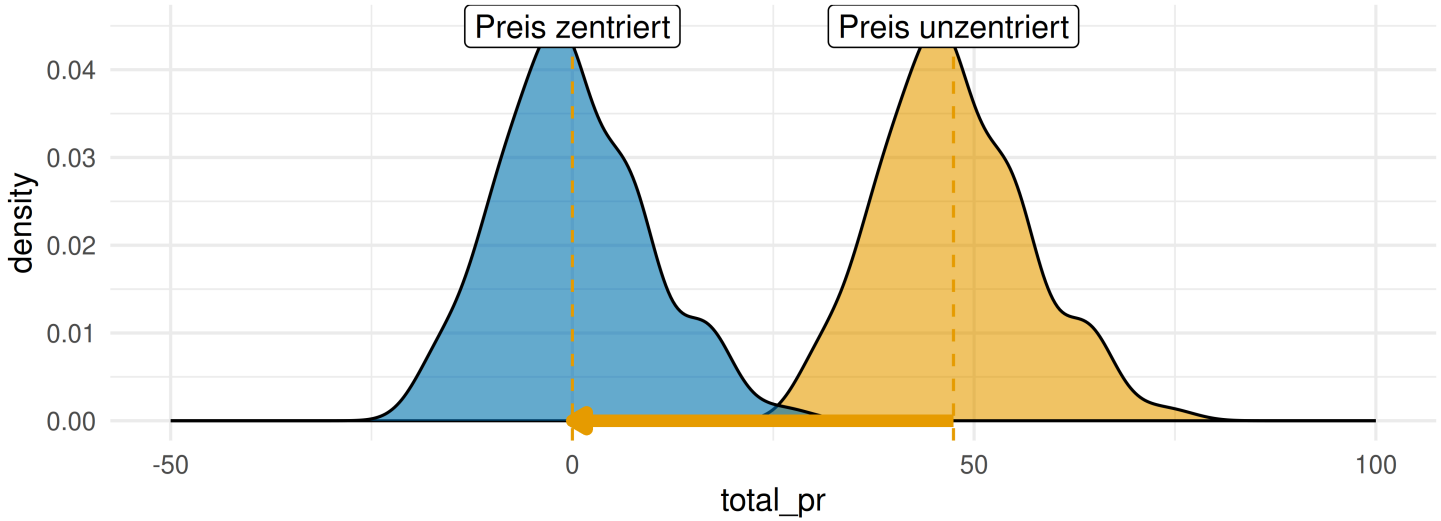
Wozu die z-Transformation?

Bei einem Datensatz ist oft schwer zu sagen, welche Ausprägungen “groß” oder “klein” sind. Die *z*-Transformation transformiert Werte in bekannte, verständliche Bereiche:

- Mittelwert wird auf Null transformiert
- Streuung (SD) wird auf 1 transformiert

Sie besteht aus zwei Schritten: **Zentrieren** und **Streuung standardisieren**.

Zentrieren



Die vertikalen gepunkteten Linien zeigen die Mittelwerte der Verteilungen.

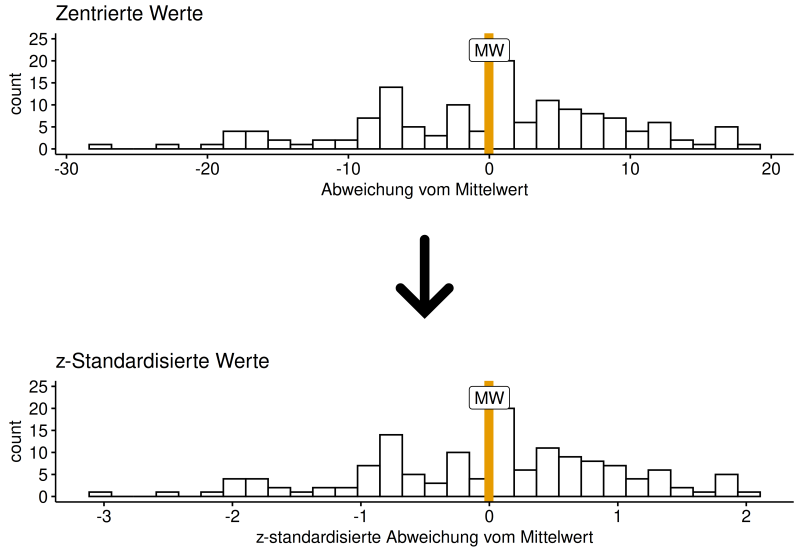
Definition: Zentrieren

Von jedem Wert einer Verteilung X wird der Mittelwert subtrahiert: $X_c = X - \bar{X}$. Der neue Mittelwert ist Null.

Streuung standardisieren

Wie viel Abweichung vom Mittelwert ist “viel”? Man setzt die Abweichung in Bezug zur typischen Abweichung (SD): weicht ein Spiel 10 € vom Mittelwert ab und beträgt die SD 10 €, ist die standardisierte Abweichung 1 (10/10 = 1).

```
1 mariokart_no_extreme <- mariokart_no_extreme %>%
2   mutate(abw_std = abw / sd(abw))
```



Definition: z-Werte

Kochrezept: (1) Abweichung vom Mittelwert berechnen, (2) durch die SD teilen.

Definition: z-Werte

Für die Variable X berechnet sich der *z*-Wert der i-ten Beobachtung: $z_i := \frac{x_i - \bar{x}}{sd_x}$

Faustregel: Extremwerte (Ausreißer), wenn $z_i \geq 2.5$ (Shimizu, 2022).

Definition: Standardnormalverteilung

Definition: Standardnormalverteilung

Eine *Standard*normalverteilung ist eine Normalverteilung mit Mittelwert 0 und Standardabweichung 1: $X \sim \mathcal{N}(0, 1)$

Jede Normalverteilung lässt sich mit der *z*-Transformation in eine Standardnormalverteilung überführen.

```
1 mariokart_no_extreme_z <- mariokart_no_extreme |>
2   mutate(total_pr_zentriert = as.numeric(center(total_pr)),
3          total_pr_z = as.numeric(standardise(total_pr)))
```

Zusammenfassung

- **Streuungsmaße**: Spannweite, MAE, IQR, Varianz, SD — quantifizieren die Modellgüte eines Punktmodells
- **MAE**: mittlerer absoluter Fehler; **Varianz/MSE**: mittlerer quadrierter Fehler; **SD/RMSE**: Wurzel davon
- Der IQR ist robuster gegenüber Extremwerten als MAE, Varianz und SD
- Ein komplexeres (sinnvolles) Modell reduziert die Streuung/den Modellfehler
- Die **z-Transformation** (zentrieren + standardisieren) macht Abweichungen vergleichbar: $z_i = \frac{x_i - \bar{x}}{sd_x}$

Literaturhinweise

- Downey (2023) — kurzweilige Einführung in die Statistik, auch zu Streuungsmaßen
- Çetinkaya-Runde & Hardin (2021) — mehr “Lehrbuch-Feeling”, frei online verfügbar

Referenzen

Çetinkaya-Runde, M., & Hardin, J. (2021). *Introduction to Modern Statistics*. https://openintro-ims.netlify.app/

Cmglee. (2015). *English: Geometric Visualisation of the Variance of the Example Distribution (2, 4, 4, 4, 5, 5, 7, 9) on w:Standard Deviation. [Artwork]*. https://commons.wikimedia.org/w/index.php?curid=39472834

Downey, A. (2023). *Probably Overthinking It: How to Use Data to Answer Questions, Avoid Statistical Traps, and Make Better Decisions*. The University of Chicago Press.

Shimizu, Y. (2022). Multiple Desirable Methods in Outlier Detection of Univariate Data With R Source Codes. *Frontiers in Psychology*, *12*, 819854. https://doi.org/10.3389/fpsyg.2021.819854